



Ege University

# TEDARIK ZİNCİRİ RISK ANALİZİNDE METODOLOJİK BİR ANOMALİ: KARA KUTU METRİĞİN SINIFLANDIRMA ETKİSİ

Meriç Özcan

Yazarlar: Meriç Özcan, Mırgavam Gavamı, Buket Gürlek  
Ege Üniversitesi, Fen Fakültesi, İstatistik Bölümü

TÜBİTAK 2209-A

# GENEL BAKIŞ

---

**01** Giriş - Amaç

---

**02** Yöntem - Metot

---

**03** Bulgular - Sonuçlar

---

**04** Tartışma ve Sonuç

---

**05** Kaynaklar

---

# GİRİŞ

Kargo taşımacılığındaki kesintiler, Tedarik Zinciri Yönetimi (SCM) için büyük bir risk teşkil ediyor. Bu çalışma, 4 veri setinden oluşturduğumuz veri tabanını kullanarak bu riskleri doğru tahmin etmeyi hedefliyor.

Temel amacımız, geliştirilen modelle SCM'yi daha güvenilir ve hızlı hale getirerek, e-ticaret müşterilerinin satın alma deneyimlerini optimize etmek ve sağlıklı bir teslimat süreci sağlamaktır.



# ÇALIŞMA AMAÇLARI

## Risk Sınıflandırma Tahmini:

Büyük kargo verilerini kullanarak yüksek doğrulukta bir risk sınıflandırma modeli oluşturmak.

## Kritik Faktörleri Belirleme:

Risk azaltmada en etkili olan operasyonel faktörleri tespit etmek.

01

02

03

04

## Veri Kalitesi ve Güvenliği:

Frequency Encoding ile veri sızıntısını sıfırlamak ve nadir riskleri modele dahil etmek.

**E-Ticaret Etkisi:** SCM çevikliğini artırarak e-ticaret müşteri deneyimini optimize etmek ve kargo risklerini minimize etmek.

# YÖNTEM - METOT

## Veri Ön İşleme:

- 4 veri seti birleştirilerek ~650.000 kayıtlı bir veri tabanı oluşturuldu.
- Hedef değişken boş olmayan 32.065 gözlem kullanıldı.
- Anomaliler temizlendi, sayısal veriler ölçeklendi, eksik değerler tamamlandı.
- One-Hot yerine Frequency Encoding uygulandı.

## Modelleme:

- Yapay Başarı: Kesinti olasılığı skoru ile model  $F1=1.00 \rightarrow$  Skor hedefi tanımlıyor.
- Gerçek Performans: Skor çıkarıldı, XGBoost ve SMOTE ile Weighted  $F1=0.6393$  elde edildi.

# YÖNTEM - METOT


## Metodolojik Denemeler:

- Kara Kutu Kırma (MLP/XGBoost Regressor):  $R^2 < 0$ , Skor çözülmedi → Kara Kutu kanıtı.
- Öznitelik Mühendisliği: Low/Moderate Risk iyileştirilemedi → Mevcut öznitelikler yeterli sinyali taşımıyor.

## Çıkarım:

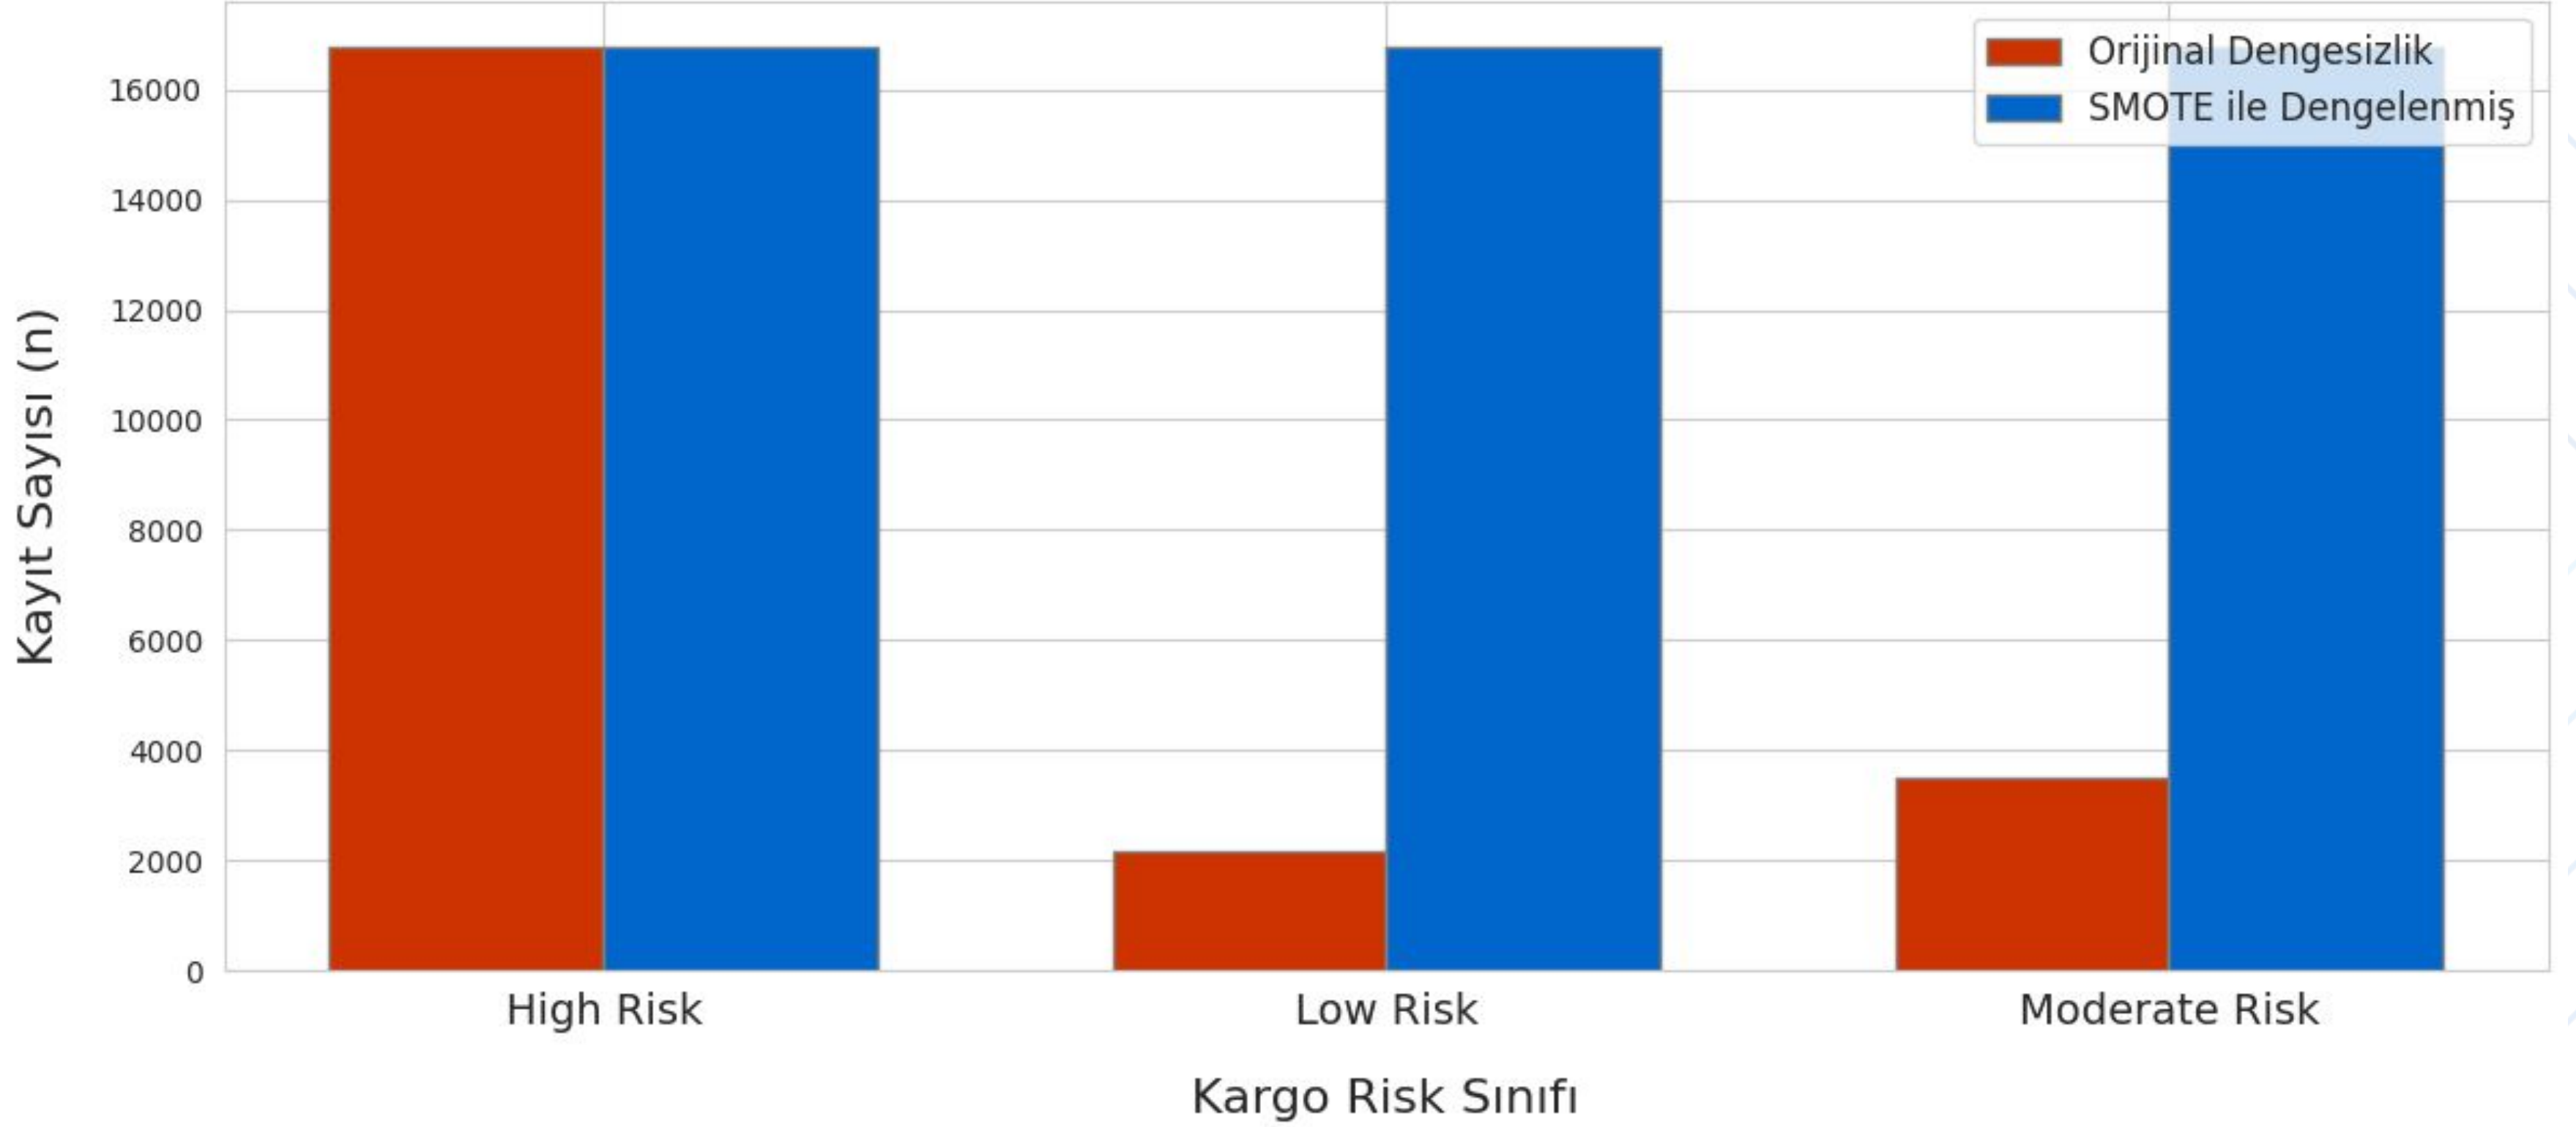
- $F1=0.6393$ , mevcut veri ile maksimum gerçek performansı temsil eder.
- Feature Importance sonuçları, eyleme dönük tavsiyelerin temelini oluşturur.

## Modelleme Öncesi Veri Kaybı ve Filtreleme





## Modelleme Öncesi ve Sonrası Sınıf Dağılımı (SMOTE Etkisi)





# NEDEN XGBOOST ?

## AÇIKLANABİLİRLİK:

- Projenin asıl amacı riski yönetmektir, tahmin etmek değil. XGBoost, DF1\_Weather ve DF1\_Traffic gibi faktörlerin yüzdesel etkisini gösteren tek güvenilir araçtır.

## GERÇEK PERFORMANS:

- 0.6393 F1-Skoru, modelin önceki 1.00'lük yapay başarının ötesindeki gerçek gücünü temsil eder. XGBoost, bu zorlu seviyede bile en yüksek kararlılığı sağlar.

## DAYANIKLILIK:

- RobustScaler ve SMOTE ile uyumu sayesinde, aykırı değerler ve sınıf dengesizlikleri karşısında dahi güvenilir sonuçlar verir.

# BULGULAR - SONUÇLAR

## KARGO RİSK ANALİZİNİN METODOLOJİK YOLCULUĞU

Kilit Amaç: Kara Kutu'yu Açma Girişimi


- Çalışmanın temel amacı, modeli domine eden tescilli DF2\_disruption\_likelihood\_score metriğinin alt formülünü çözmek ve riski minimize edecek operasyonel eylemleri belirlemektir.

## I. YAPAY BAŞARI:

- Çalışma, DF2\_disruption\_likelihood\_score girdisiyle eğitilen XGBoost Sınıflandırma Modelinin  $F1=1.00$  ile kusursuz bir başarı göstermesiyle başladı. Bu skor, modelin skorun sonucunu okuyarak risk sınıfını çözdüğünü gösteren bir yapay başarıydı.



## DF2 Skorunun Baskınlığı: Pareto / Kümülatif Etki Analizi






## II. TERSİNE MÜHENDİSLİK (XGBOOST REGRESYONU):

- Bu başarının kökenini sorgulamak için XGBoost Regressor ile kesinti olasılığı skorunu tahmin etme girişimi yapıldı. Sonuç  $R^2$  değeri  $-0.1235$  ile negatif çıktı. Bu, skorun lineer bir kombinasyonla çözülmemeyeceğini gösteren ilk kanıttı.

## Regresyon Başarısızlığı: $R^2$ Karşılaştırması (Rastgele Eşiği)

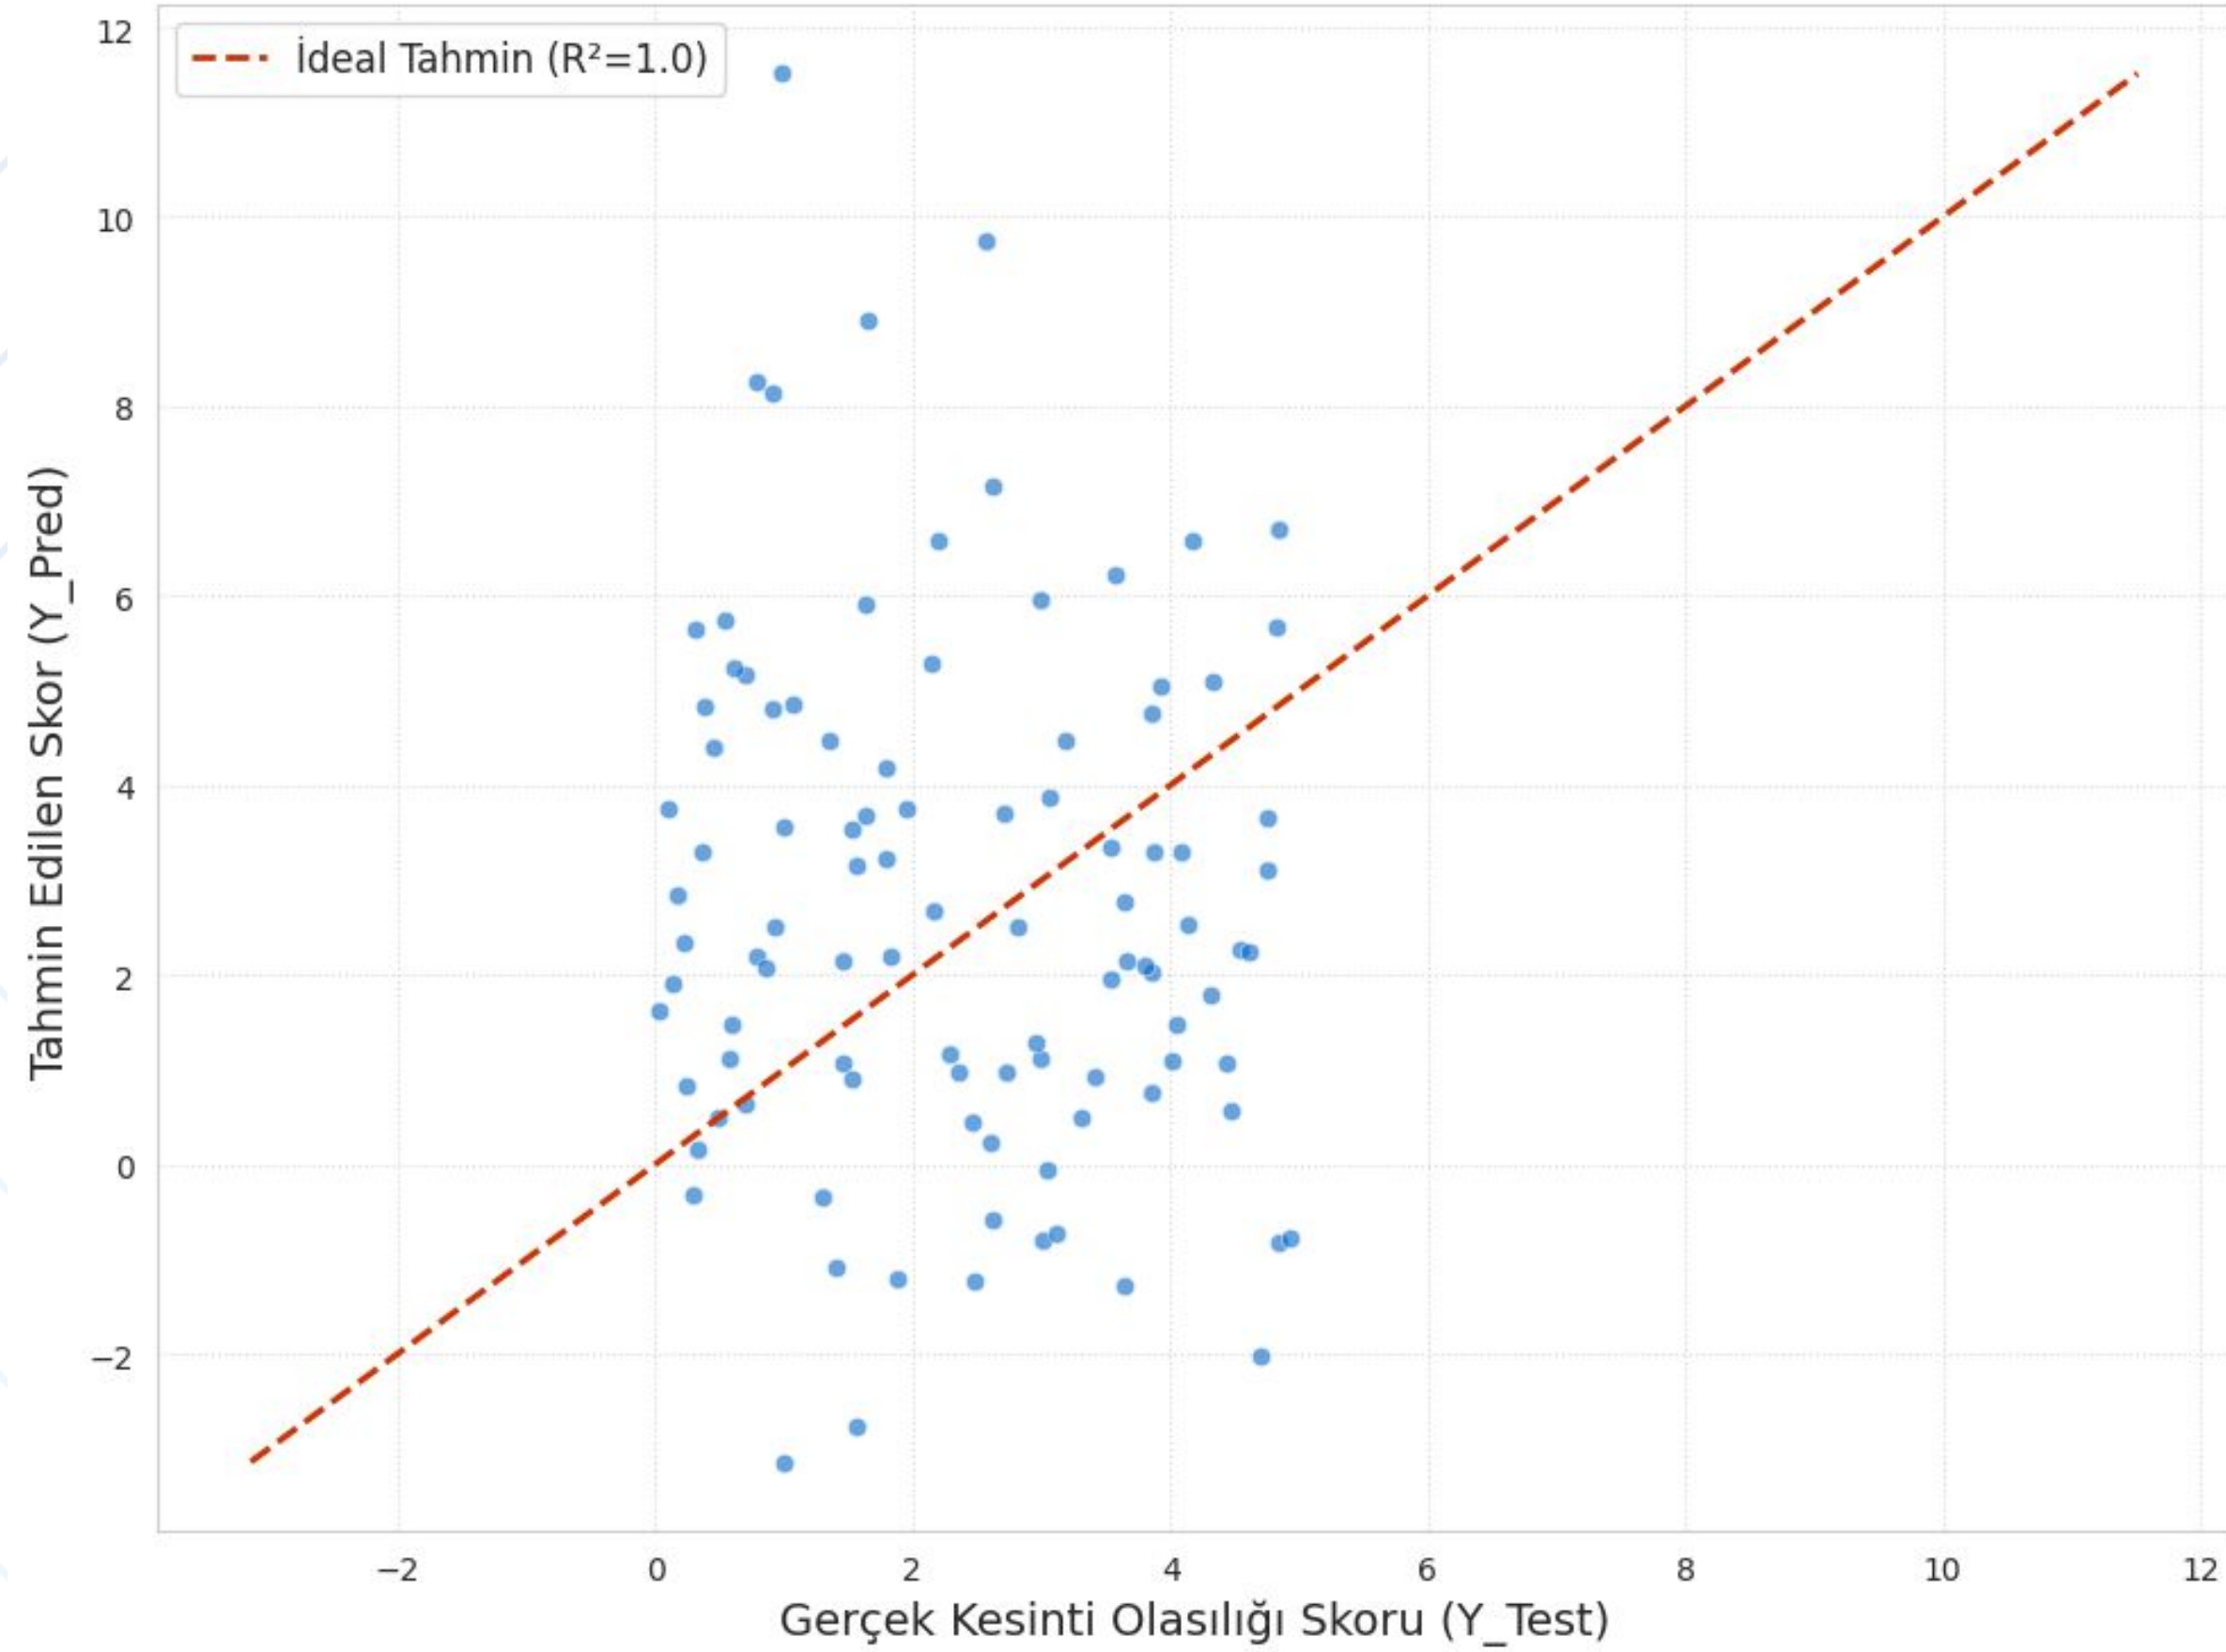


# III. ÖZELLİK MÜHENDİSLİĞİ VE İSPAT

- Skorun alt bileşenlerini yakalamak amacıyla, Interaction ve Pseudo Index gibi basit kural tabanlı öznitelikler yaratıldı. Bu girişimler, öznitelik önem düzeyini anlamlı ölçüde değiştirmekte başarısız oldu.
- Model, dolaylı ve hatalı (Pseudo) öznitelikleri kullanmak yerine, hedefi mükemmel yansıtan `DF2_disruption_likelihood_score`'u kullanmayı tercih etmiştir. Bu da, yapay özniteliklerimizin öneminin 0.001 seviyesinde kalmasına yol açmıştır.



## Öznitelik Mühendisliği Sonrası İlişki Kurulamaması (MLP Regresyonu)





# YARATILAN SENTETİK ÖZNİTELİKLERİN TANIMI

## 1. Interaction\_RI\_Weather (Etkileşim Terimi)

- Amaç: Basit Bir Etkileşim Kuralını Yakalamak.
- Tanım: Tedarikçi Risk Endeksi'nin RI değeri ile Hava Durumu Şiddeti Severity puanının çarpımından elde edilen yeni bir değişkendir.
- Mantığı: SCM'de riskler nadiren tek bir kaynaktan gelir. Hipotez, kötü hava koşulları ile güvenilmez bir tedarikçi riskinin aynı anda gerçekleşmesi durumunda, toplam riskin toplamsal değil, katlanarak çarpımsal artmasıdır. Bu öznelite, bu katlanmış non-lineer etkiyi modellemeye çalışmıştır.

# YARATILAN SENTETİK ÖZNİTELİKLERİN TANIMI

## 2. Pseudo\_SCM\_Index (Sözde SCM Endeksi) Tanımı

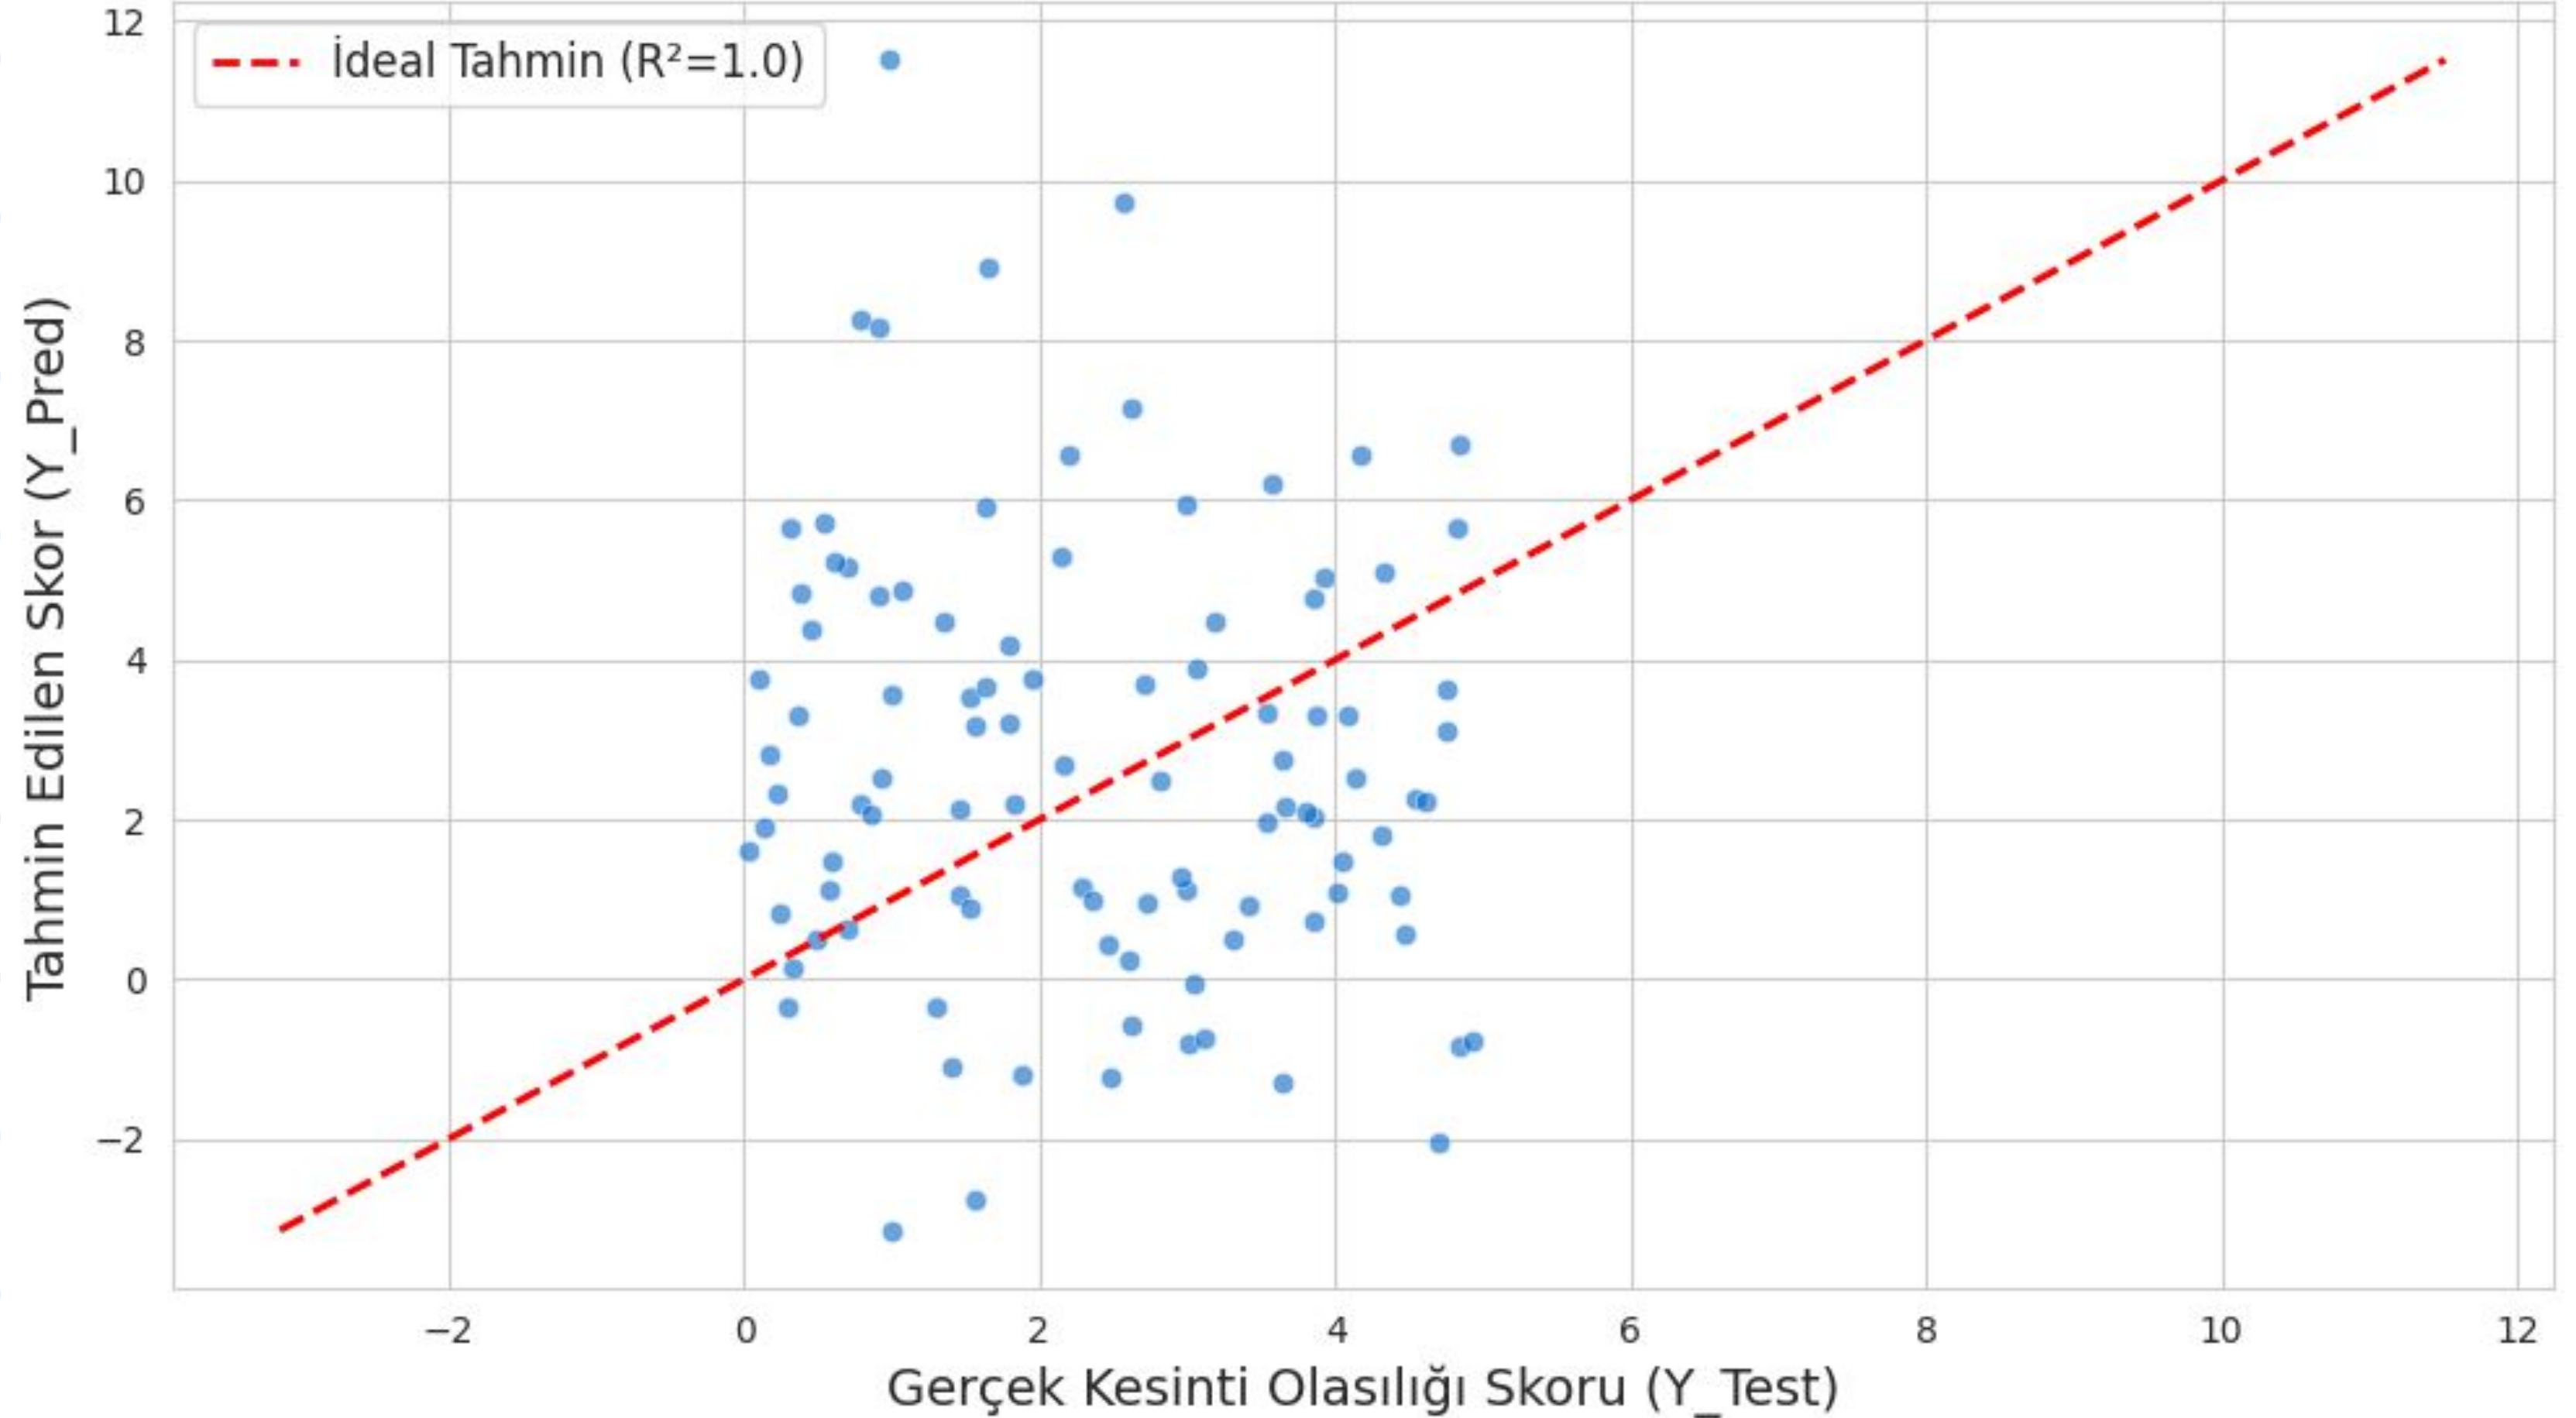
- Amaç: En Önemli 3 Eyleme Dönük Faktörü Basitçe Birleştirmek.
- Tanım: Tedarikçi Riski, Trafik Yoğunluğu Seviyesi ve Liman Sıkışıklığı Seviyelerinin toplamından oluşturulmuş yapay bir toplam risk endeksidir.
- Mantığı: DF2\_disruption\_likelihood\_score'un bu üç temel operasyonel faktörün ağırlıklı bir toplamı olabileceği varsayılmıştır. Bu öz nitelik, Kara Kutu skoru yerine, eyleme dönük kendi sade risk skor formülümüzü yaratma girişimiydi.

## IV. AŞIRI KARMAŞIK MODELLEME

- Basit yöntemlerin ardından, DF2\_disruption\_likelihood\_score'un karmaşık non-lineer bir mimariyle türetildiği varsayımıyla Yapay Sinir Ağı (MLP Regresyonu) uygulanmıştır.
- Sonuçlar,  $R^2 \approx -0.5644$  ile modelin başarısız olduğunu göstermiştir. Bu bulgu, söz konusu skorun tescilli kuralların ötesinde bir Kara Kutu Metriği olduğunu kesin olarak kanıtlamaktadır.
- Önem: Skorun arkasındaki mantık, ne lineer ne de non-lineer geleneksel modellerle yeniden üretilememekte; bu da onu operasyonel analizlerde ayrıcalıklı ve “kullanıma hazır” bir ölçüm hâline getirmektedir.

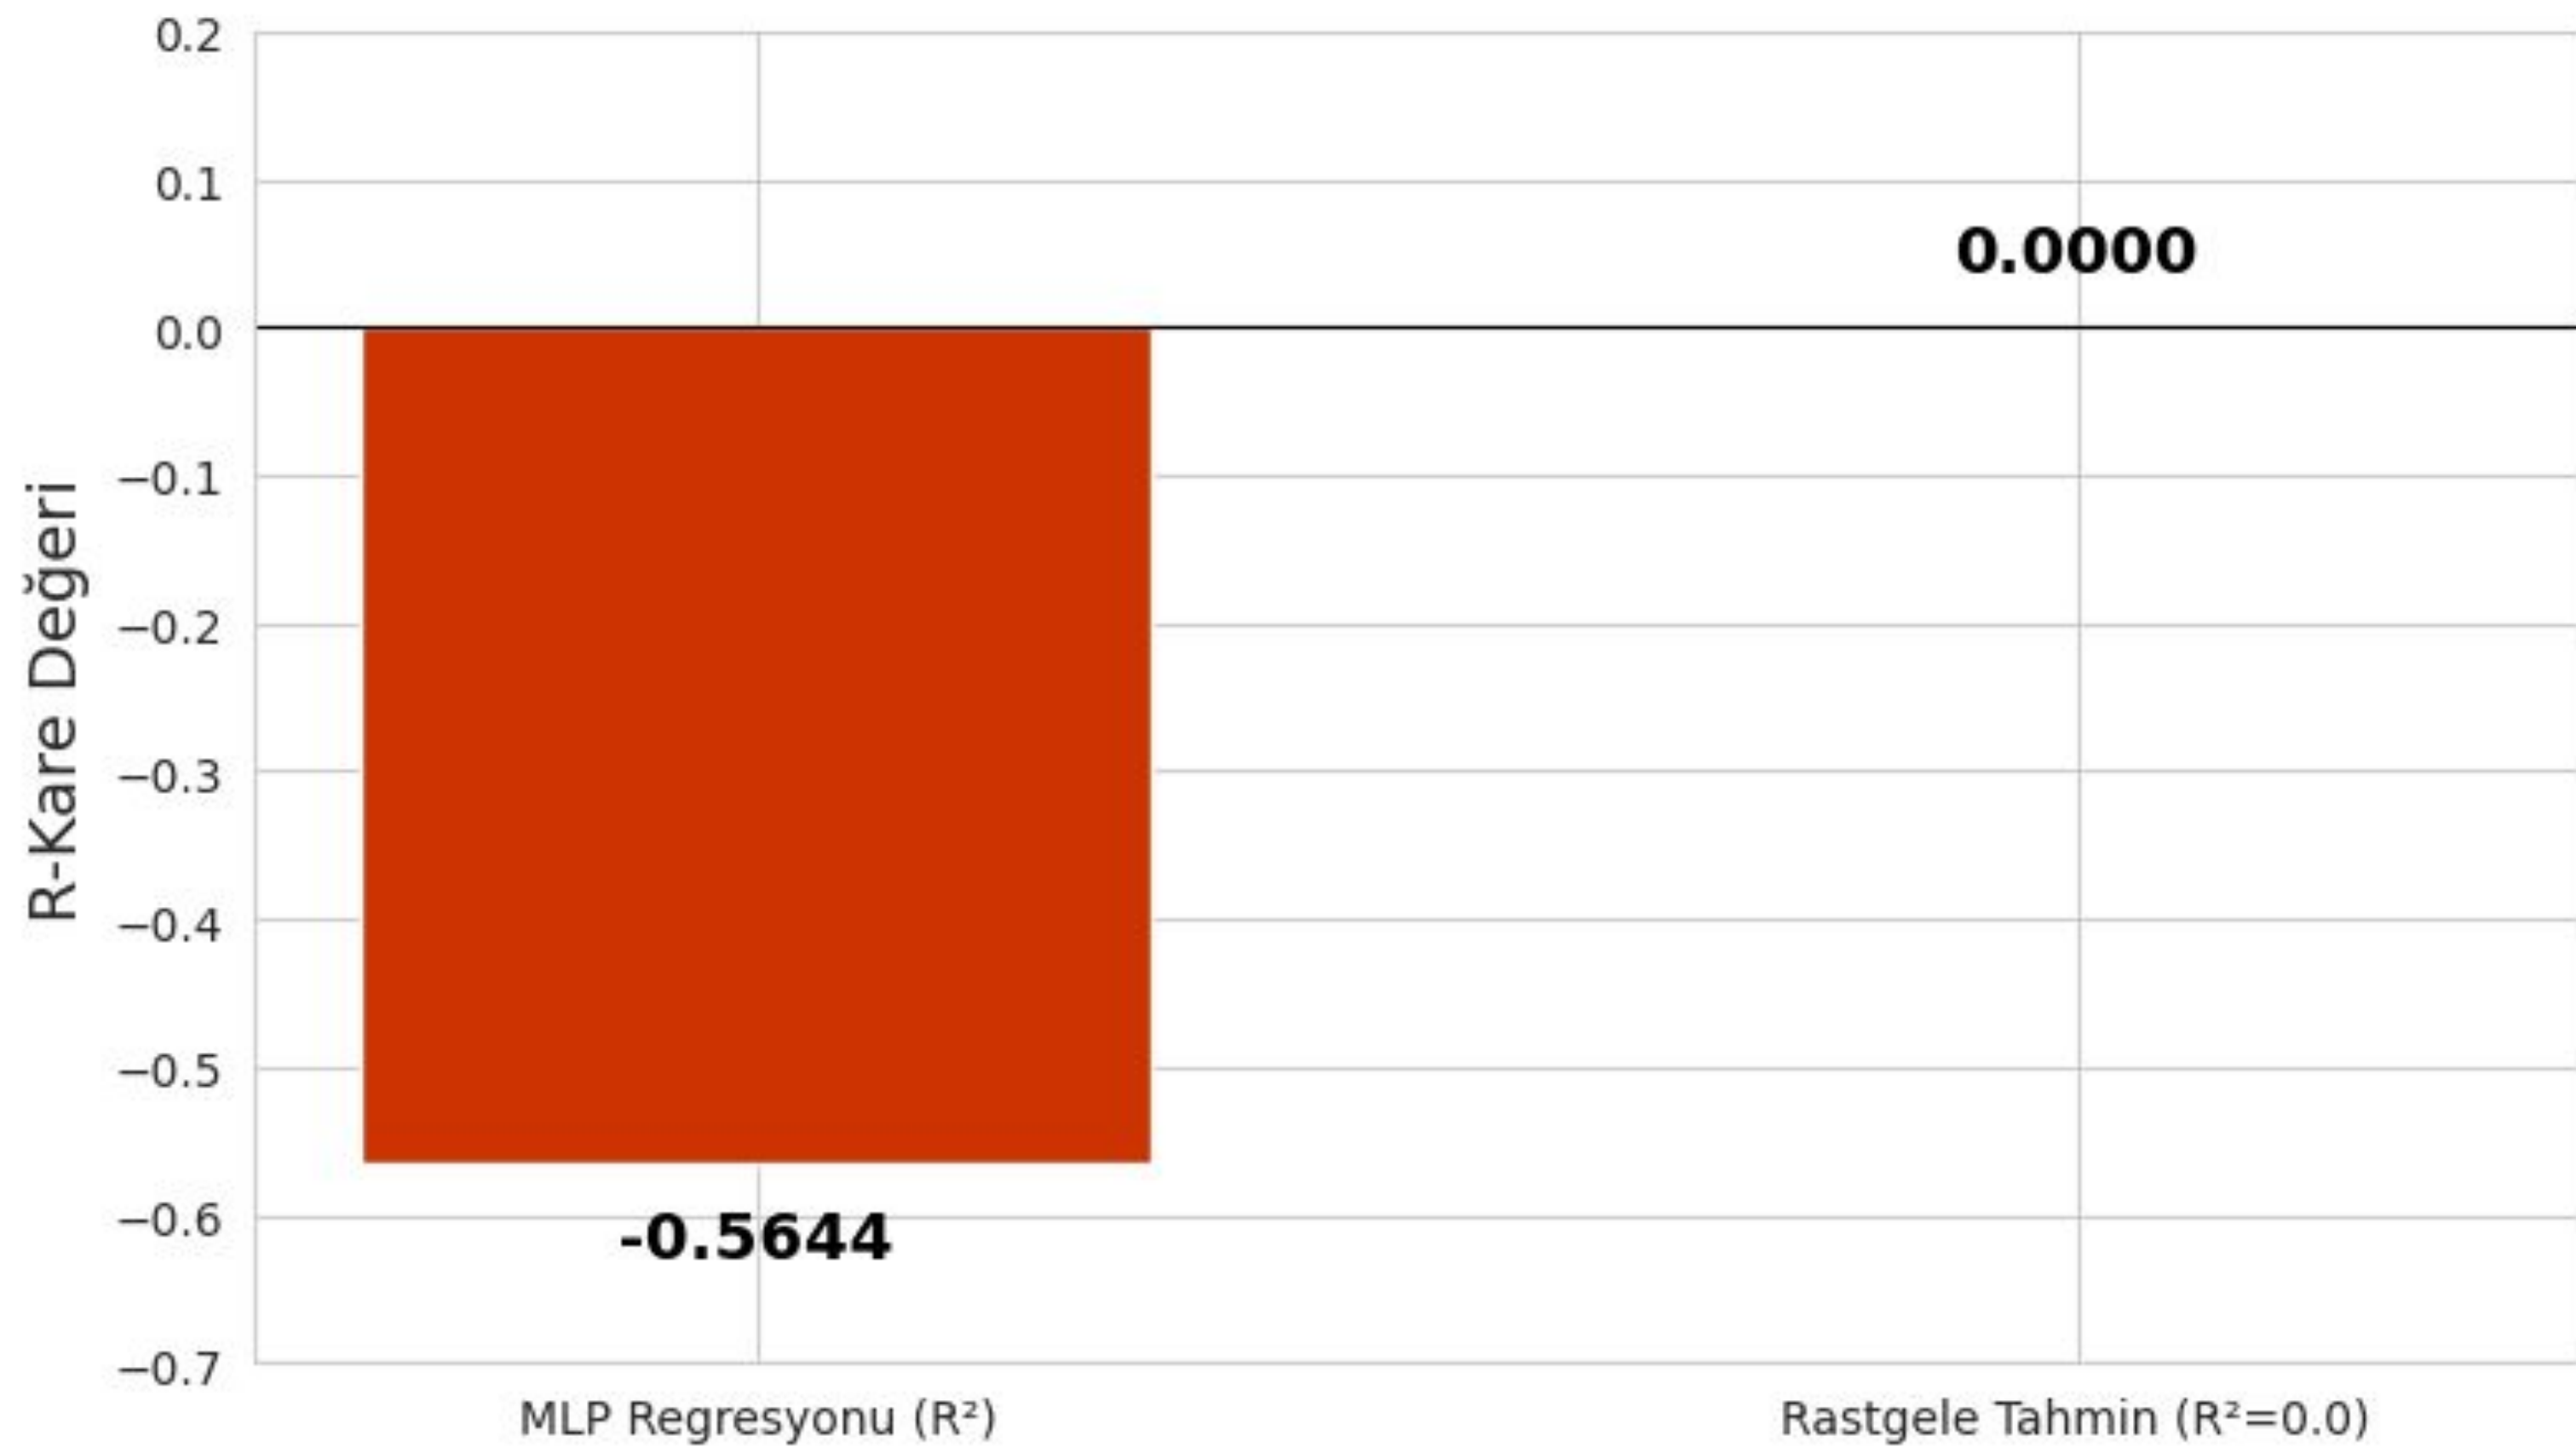


## DF2 Skor Tahmini: Gerçek Değer vs. Yapay Sinir Ağı Tahmini (MLP)

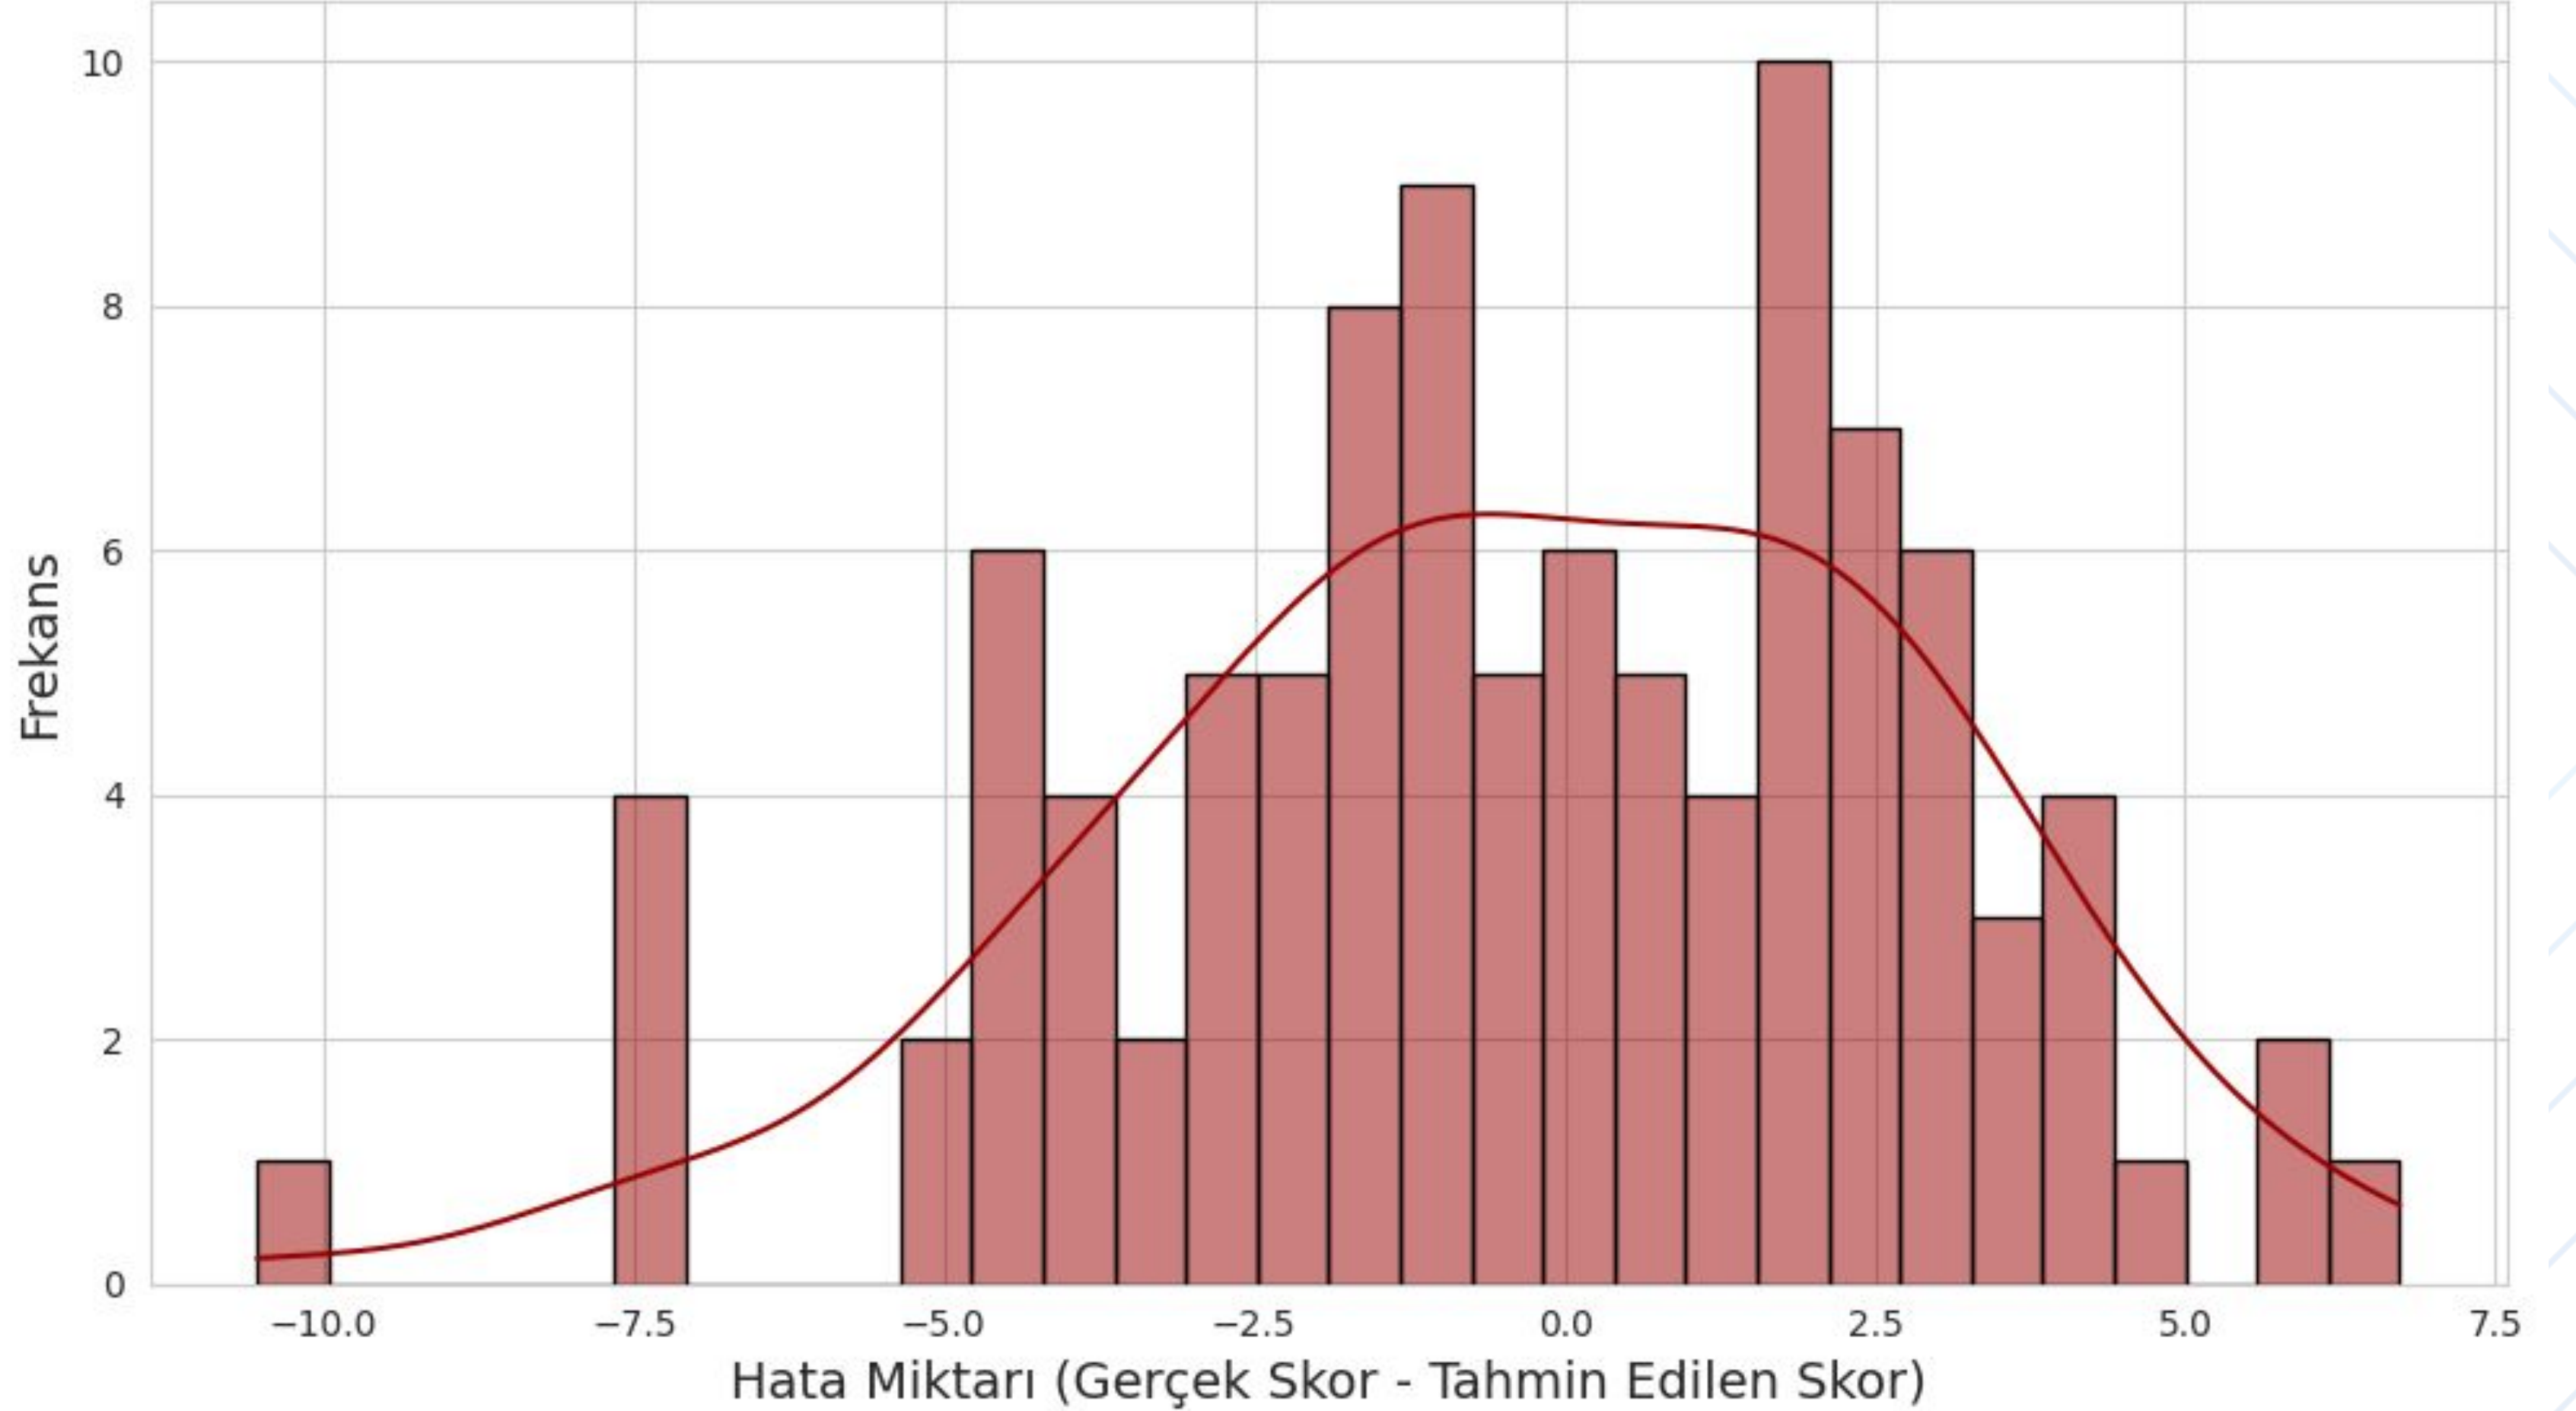




## MLP Regresyonu R-Kare ( $R^2$ ) Karşılaştırması



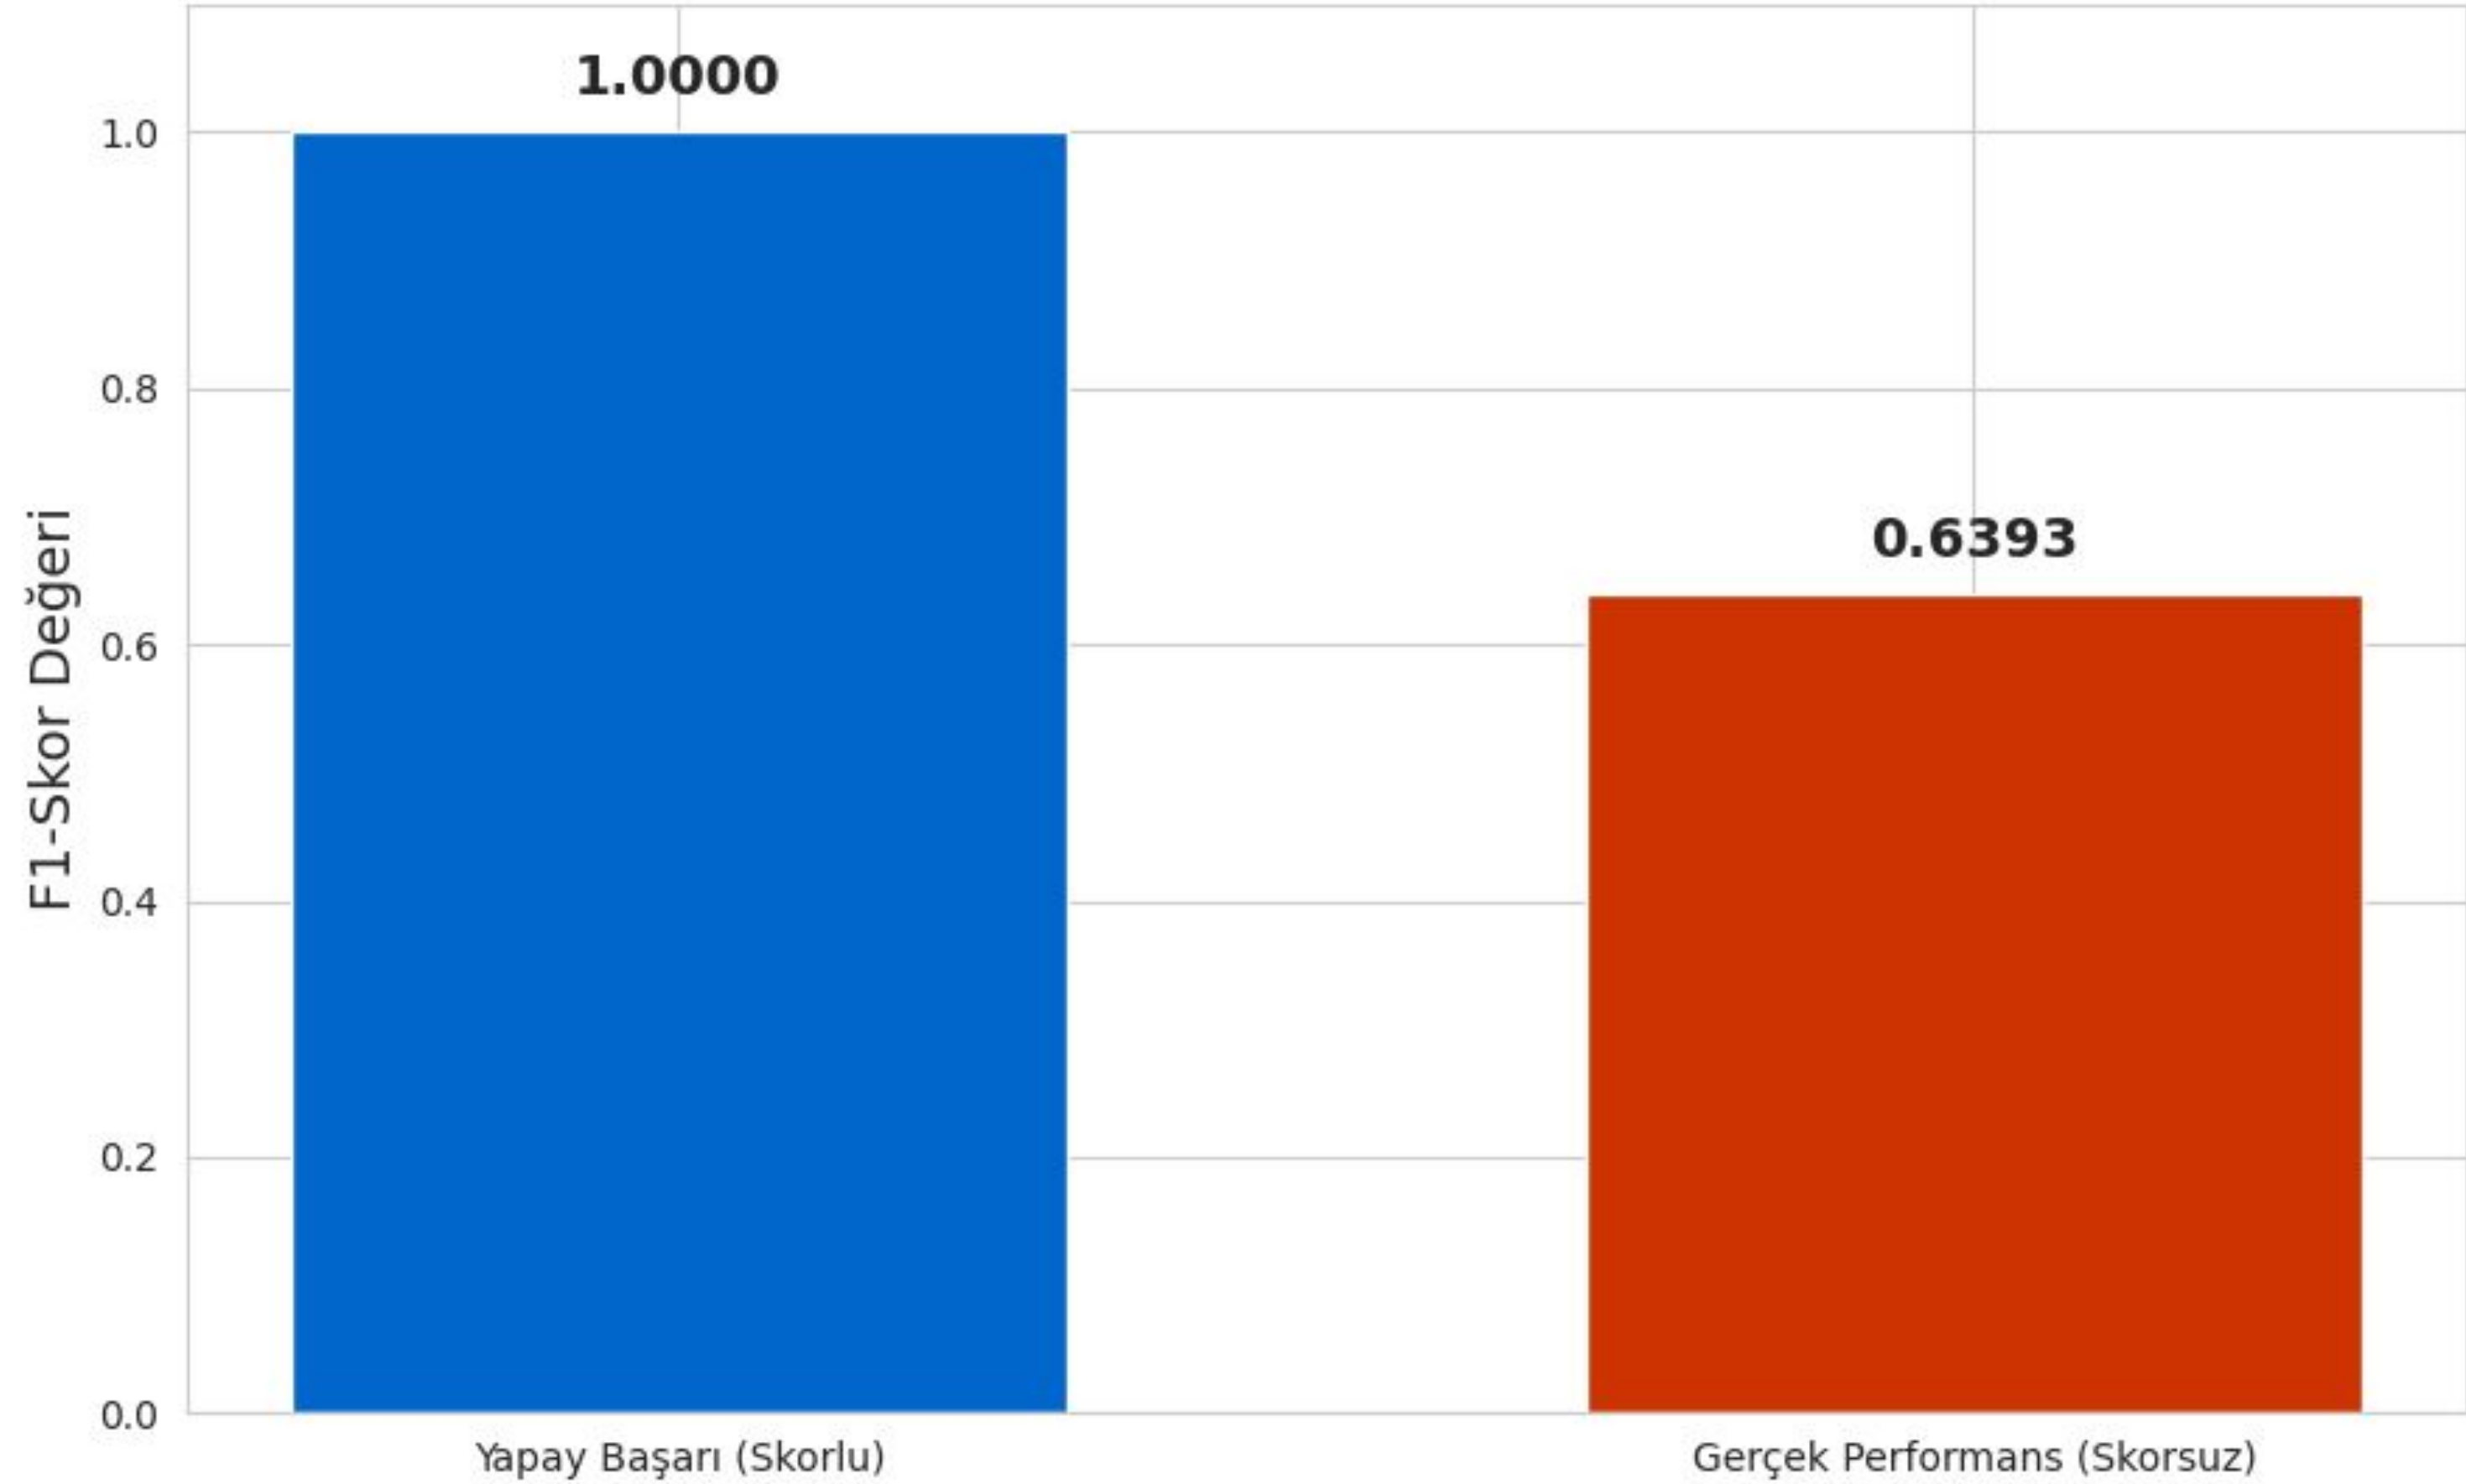
## MLP Regresyon Hatalarının Dağılımı (RMSE: 3.24)



# V. FINAL ÇÖZÜMÜ: GERÇEK PERFORMANS DEĞERLENDİRMESİ


- Girdi Çıkarımı: DF2\_disruption\_likelihood\_score tamamen kaldırıldı.
- Performans: XGBoost F1-Skoru 0.6393 seviyesine düştü; önceki 1.00'lik yapay performans ortadan kalktı.
- Yorum: Bu düşüş, modelin artık bağımsız çevresel ve operasyonel faktörlere dayalı tahmin yaptığını gösteriyor.
- Önem: 0.6393 değeri, modelin gerçek dünyadaki tahmin kapasitesini ve güvenilirliğini yansıtıyor; yani artık “yapay duvar” etkisi yok.

## DF2 Skorunun Çıkarılmasının F1-Skoruna Etkisi

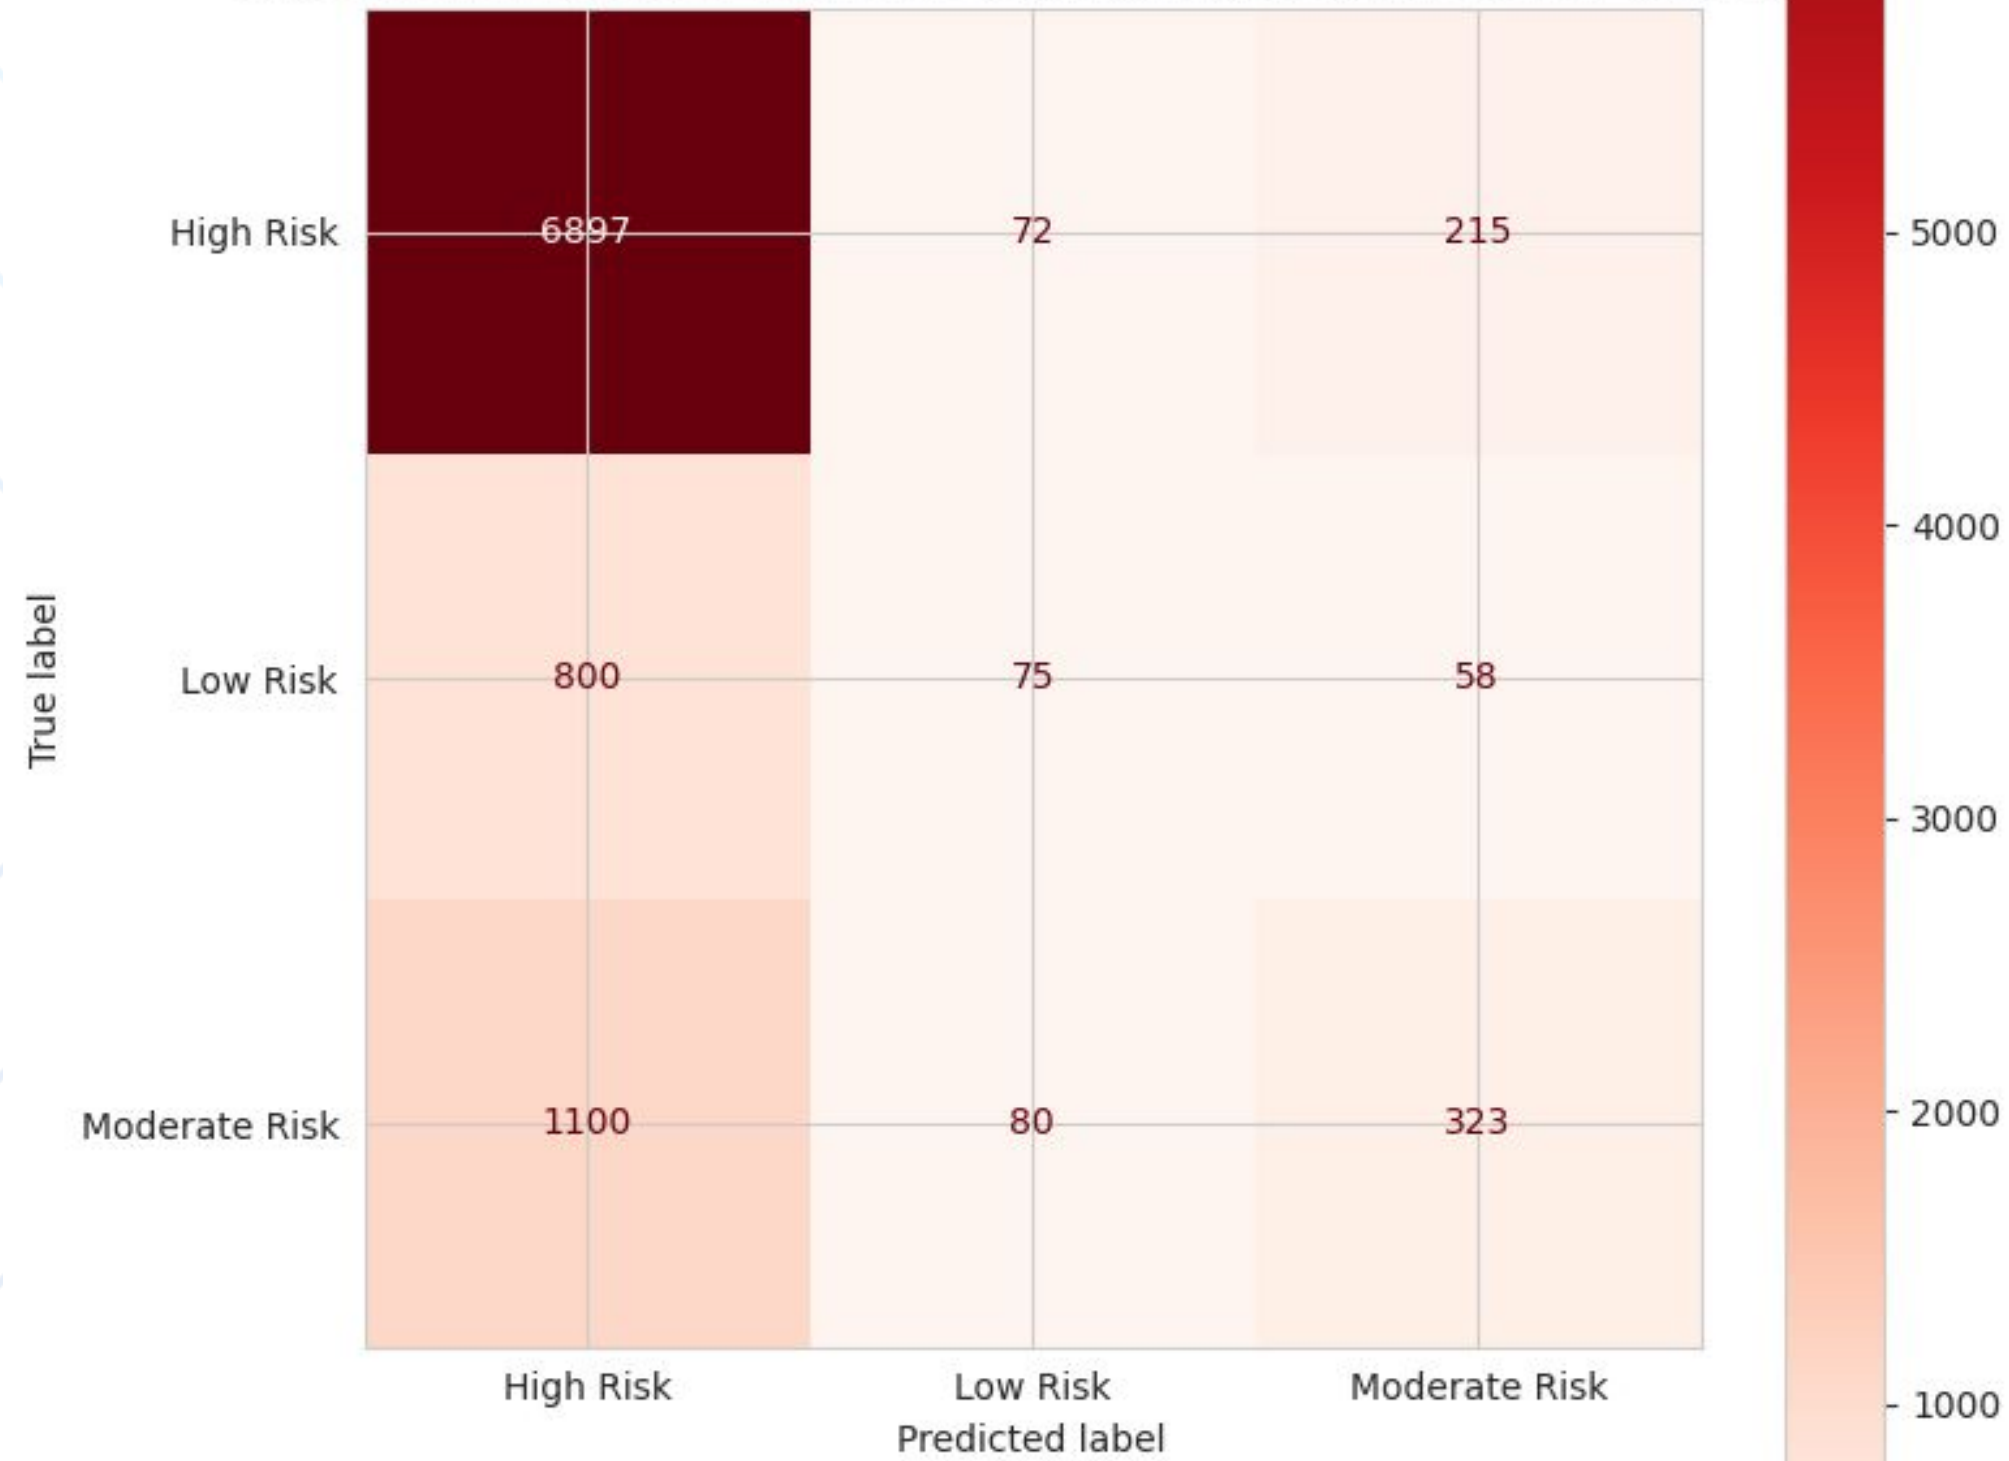




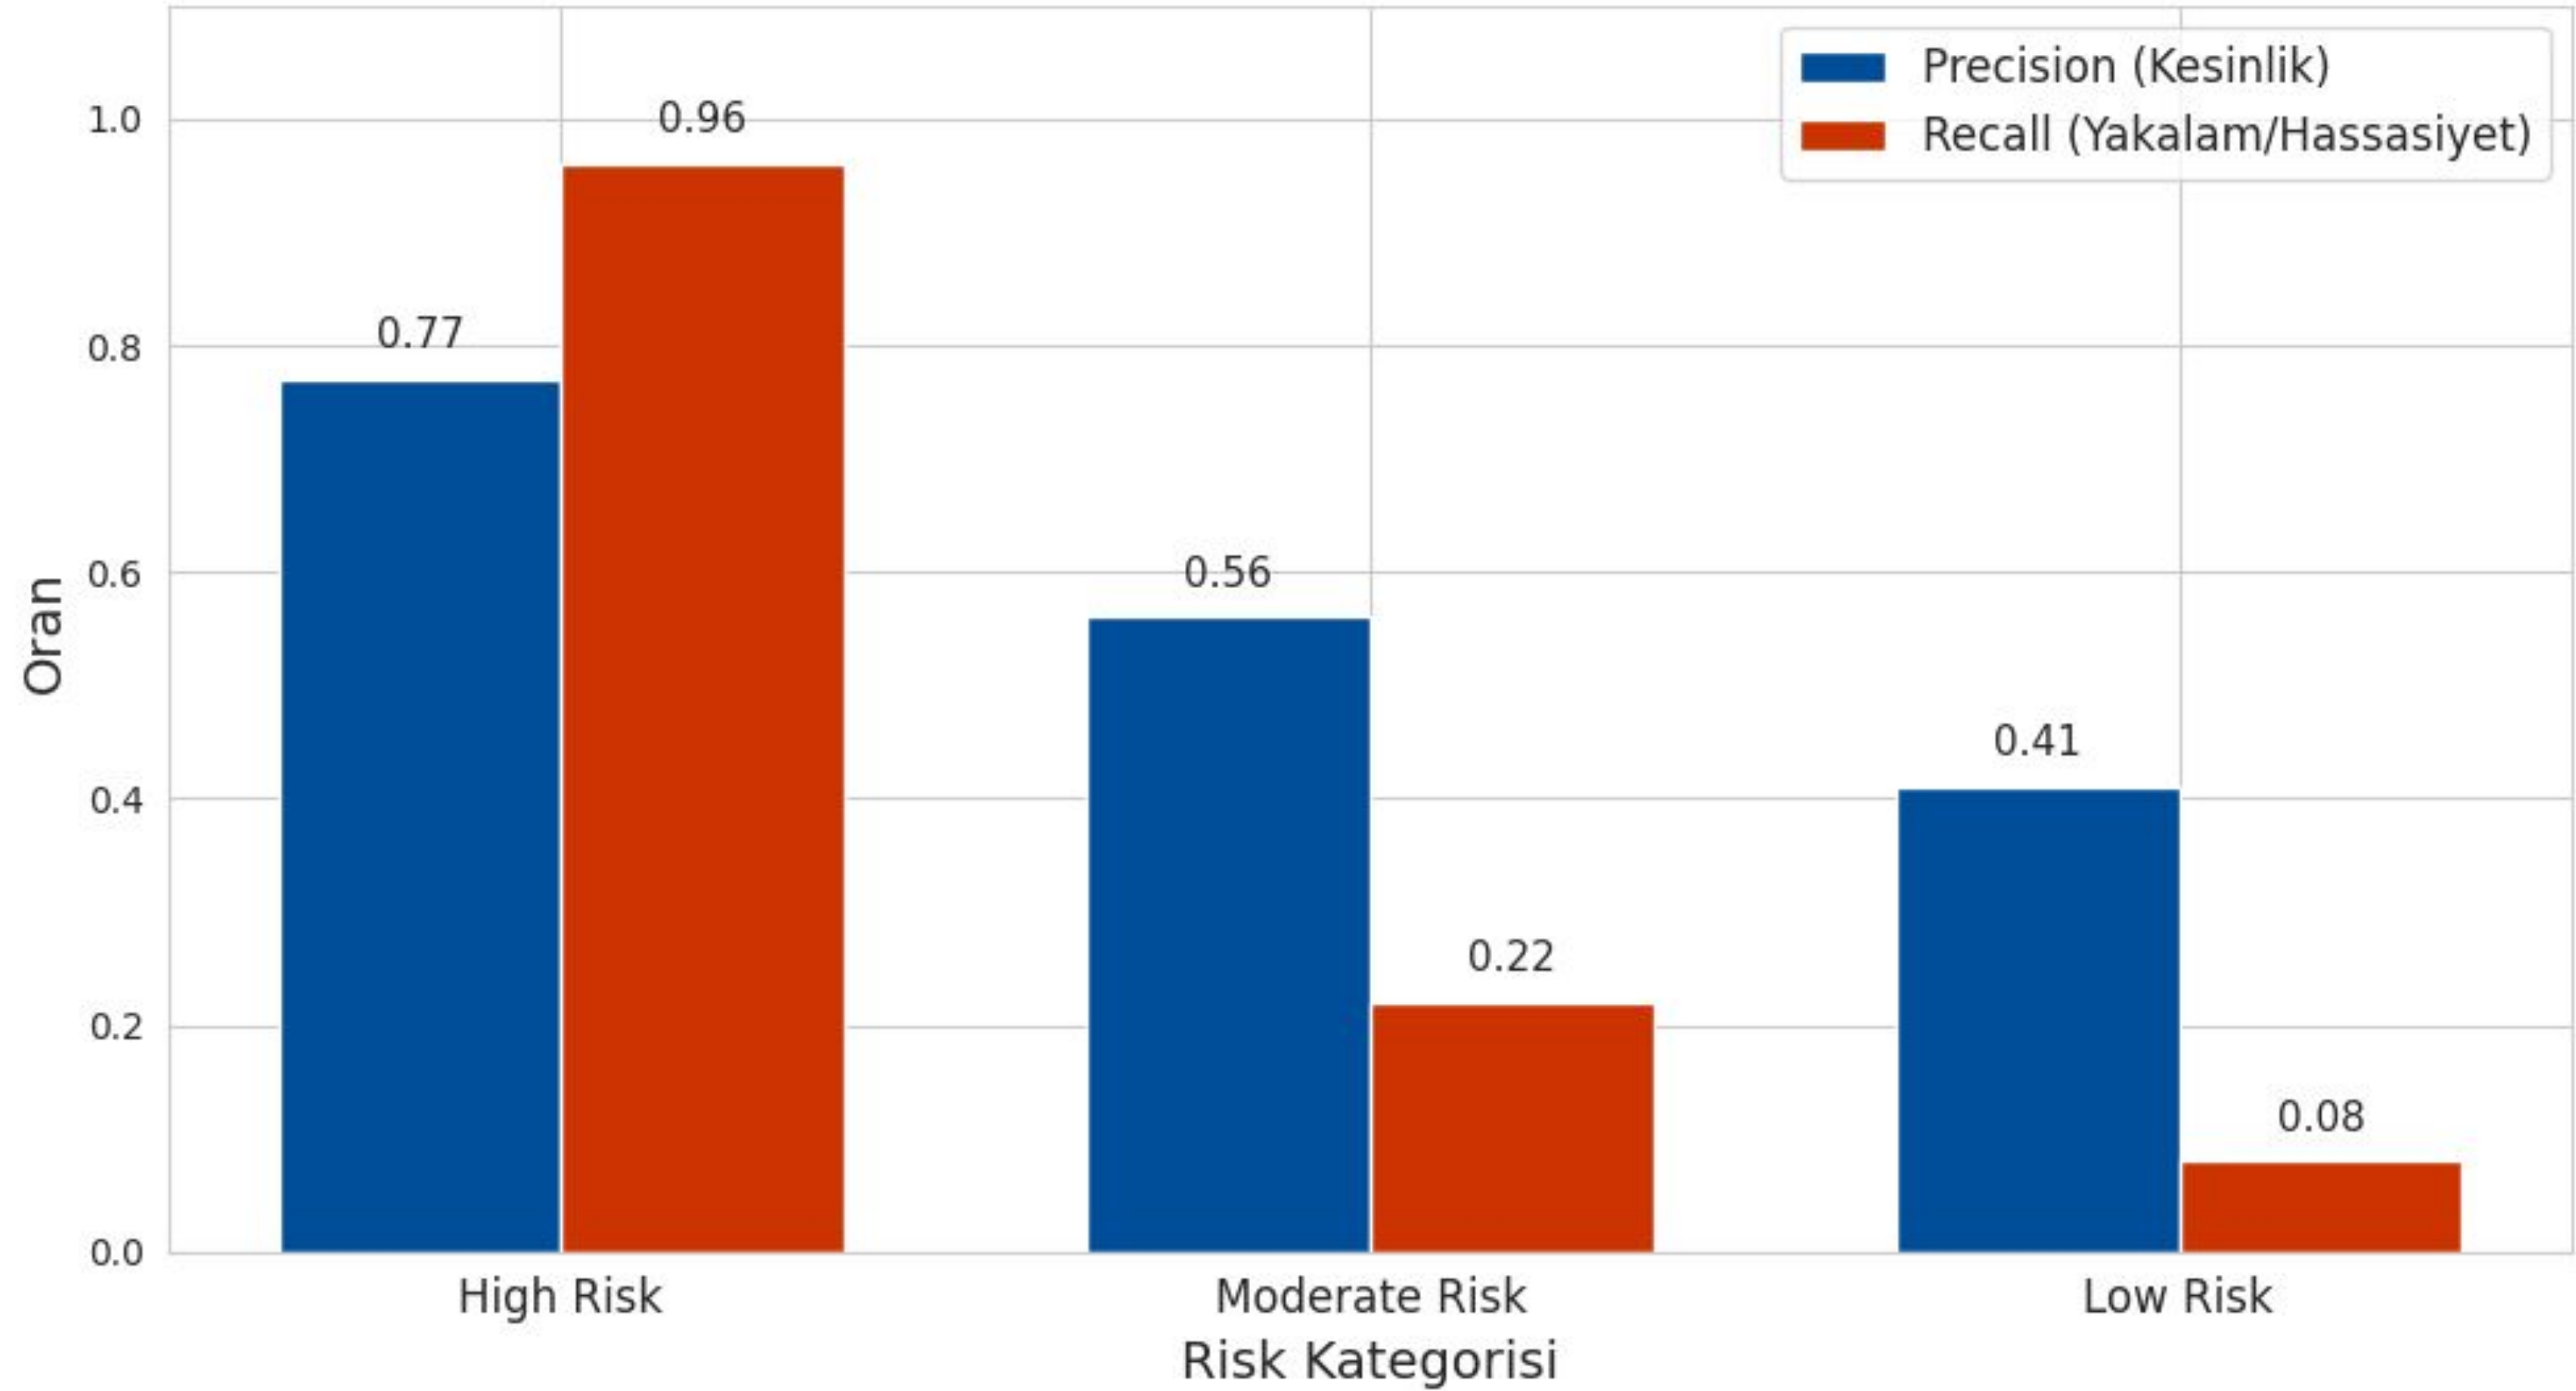
## SKORSUZ MODEL: Kargo Riskini Belirleyen Eyleme Dönük Faktörlerin Gerçek Gücü



Skorsuz Model: Hata Dağılımı (Confusion Matrix)

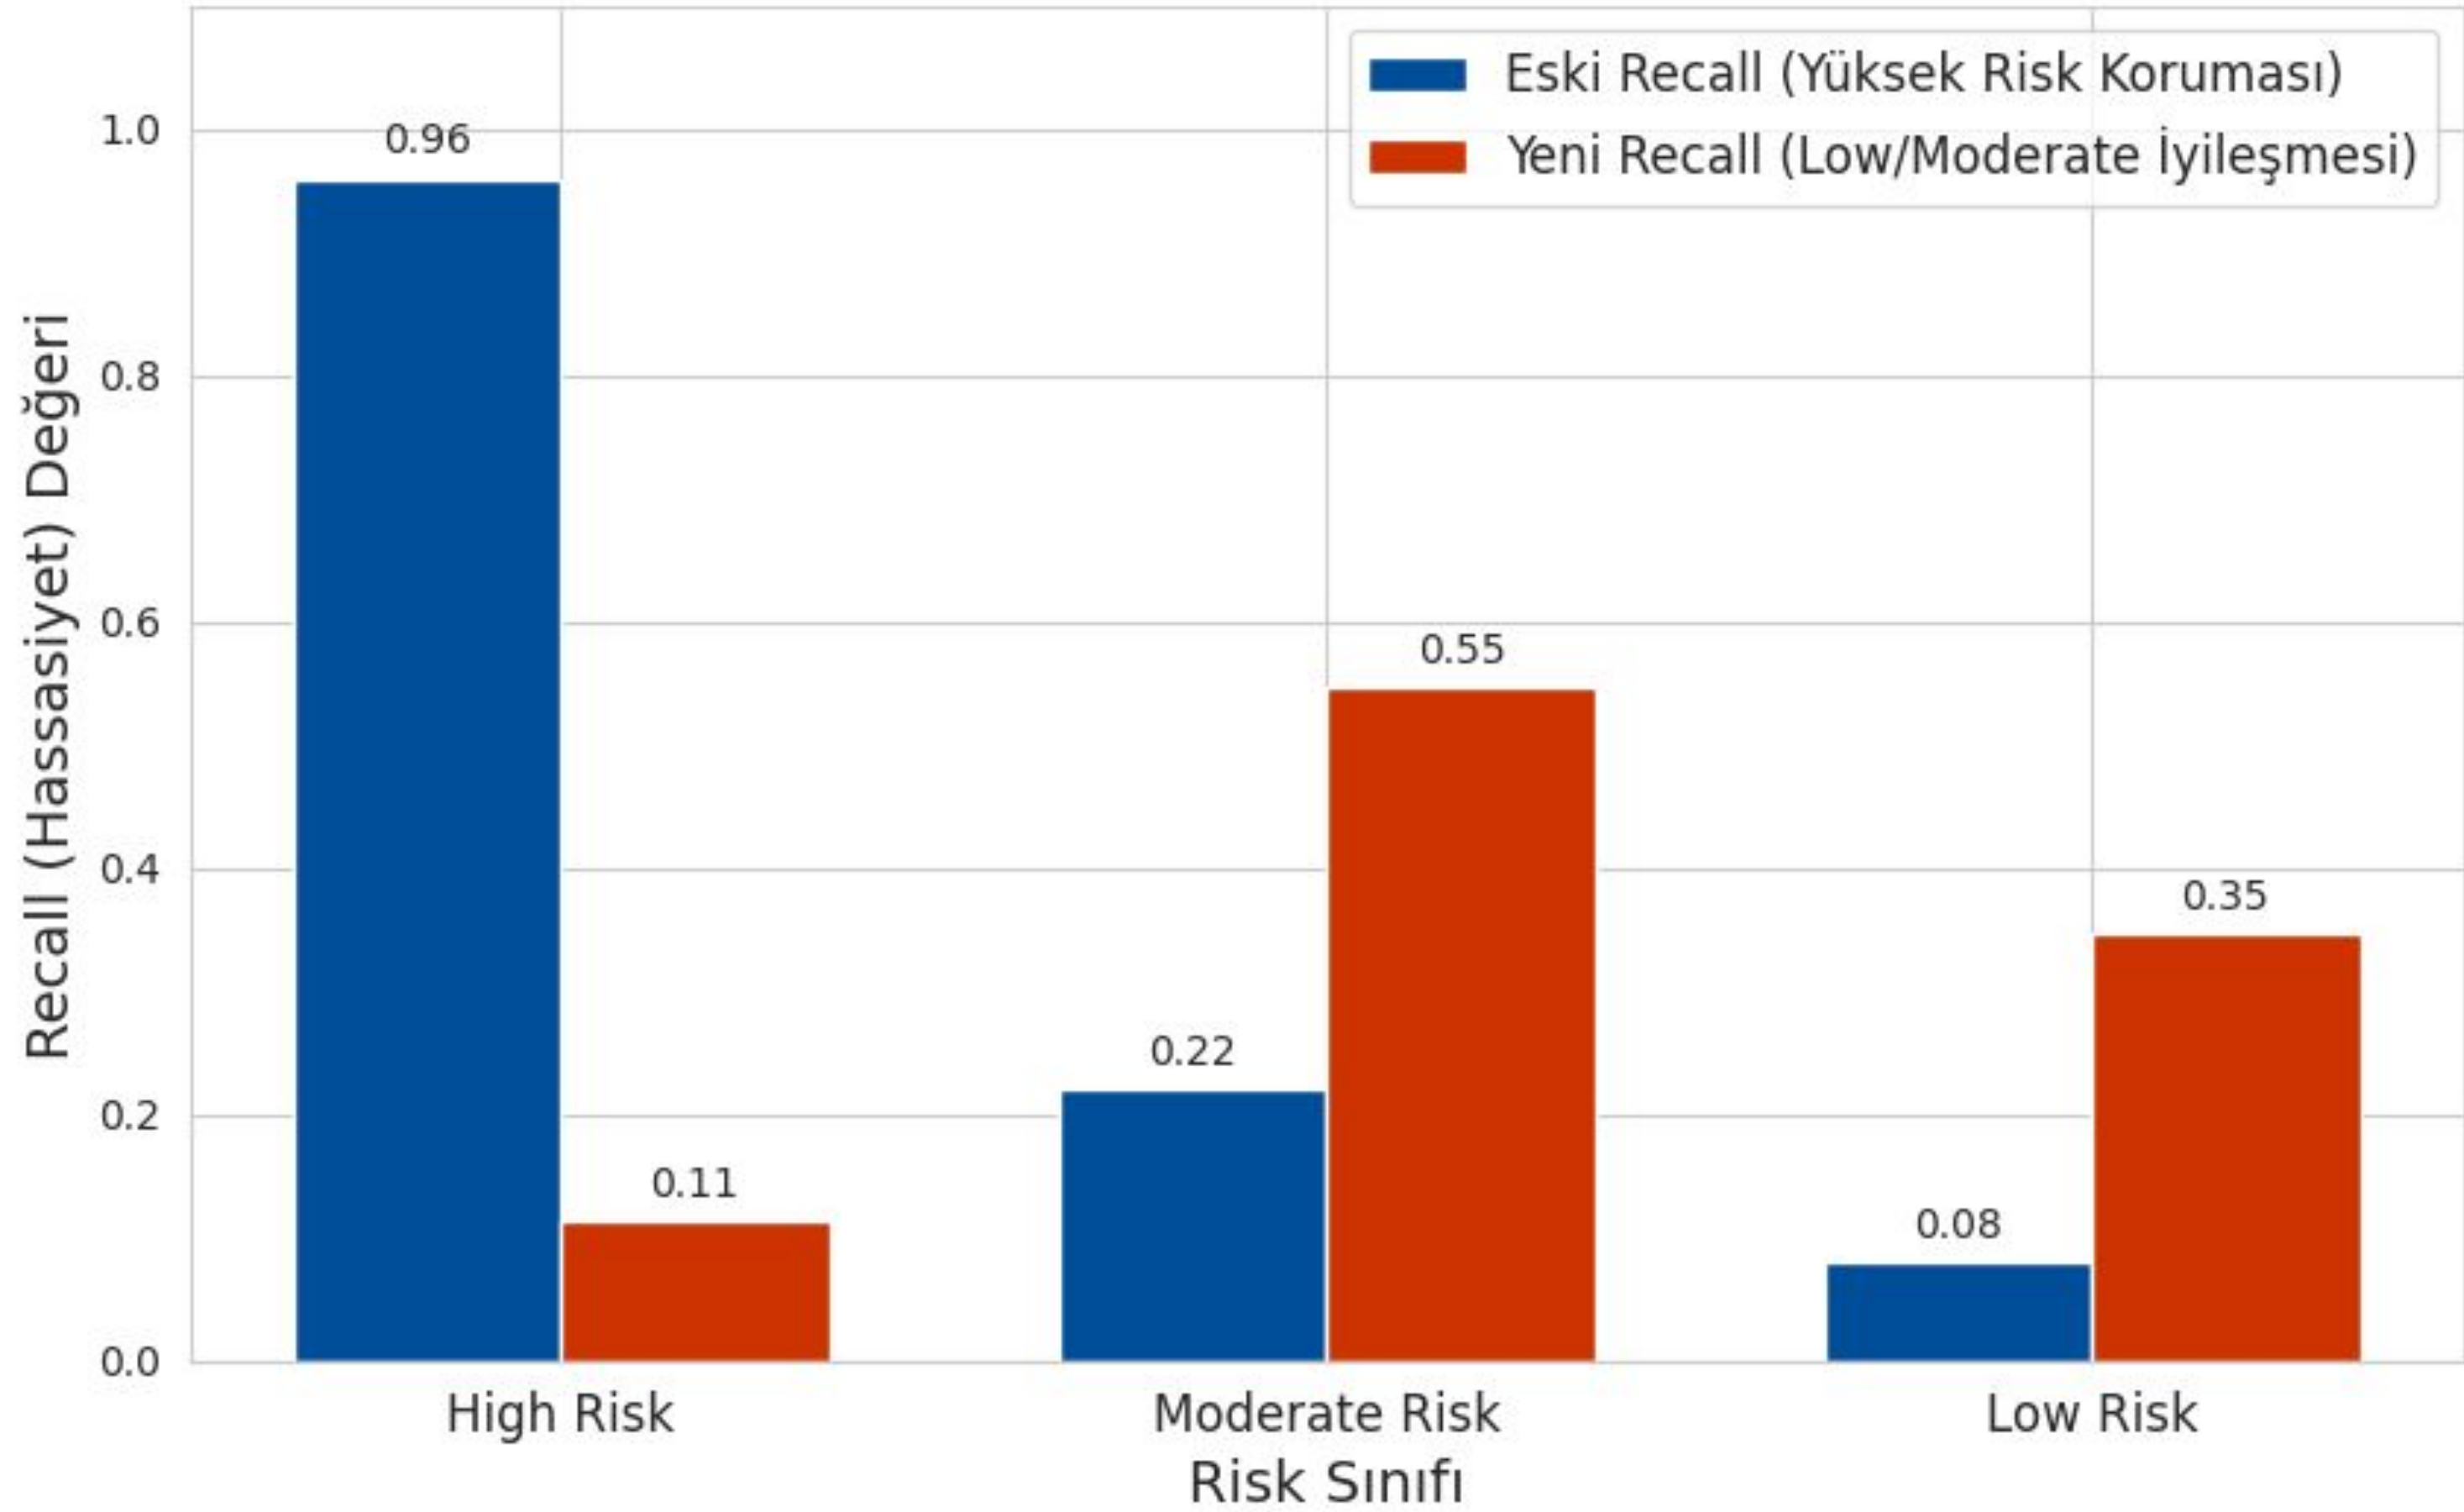


## Risk Kategorisi Tahmin Başarısı: Precision vs. Recall (Skorsuz Model)






## SMOTE-ENN: Risk Yakalama Hızındaki Çelişki



## RandomizedSearchCV Sonuçları: High Risk Korumasına Karşılık Azınlık Sınıfı Feda



**Low/Mod Risk Feda Edildi**

## VI. YENİ ÖZNİTELİK EKLEME


Modelin çözülmezliğini test etmek ve Low/Moderate Risk sınıflarını iyileştirmek için çeşitli sentetik sinyaller üretildi:

- $\text{Interaction\_RI\_Weather} = \text{Tedarikçi Riski} \times \text{Hava Şiddeti} \rightarrow \text{Etkisiz}$
- $\text{Pseudo\_SCM\_Index} = \text{Tedarikçi} + \text{Trafik} + \text{Liman} \rightarrow \text{Modeli güçlendirmede}$
- $\text{DF1\_OP\_Risk\_Index} = \text{Hava} + \text{Trafik}$
- $\text{SCM\_FIN\_Index} = \text{Finansal Risk Toplamı} \rightarrow \text{Gizli sinyal bulunamadı}$

Sonuç: Hiçbiri modeli geliştirmede. 0.6393 F1-Skoru, veri setinin aşılmaz performans sınırını göstermektedir.




**Risk Kategorisi Tahmin Başarısı: Precision vs. Recall (Skorsuz Model)**



# PERFORMANS VE METODOLOJİ

- Yapay Başarı: F1 Skoru 1.00 – DF2 değişkeni modelin yüzde 97'sini açıklayarak yapay bir mükemmellik oluşturdu.
- Kara Kutu İspatı:  $R^2$  -0.56 – MLP regresyonunun başarısızlığı, DF2'nin mevcut özniteliklerle açıklanamayacak bir kara kutu metriği olduğunu gösterdi.
- Gerçek Performans: F1 Skoru 0.639 – DF2 çıkarıldığında modelin ulaşabildiği gerçek tahmin gücü belirlendi.
- Sonuç: Modelin sınırı 0.639 düzeyindedir; bu değer operasyonel faktörlerle elde edilebilecek

## SKORSUZ MODEL: Kargo Riskini Belirleyen Eyleme Dönük Faktörlerin Gerçek Gücü





# KILIT BULGULAR

- Skorsuz model ( $F1=0.6393$ ) analizi, kargo riskini azaltmak için kritik operasyonel alanları açıkça ortaya koymuştur. En etkili dört faktör sırasıyla: hava durumu (14.85%), trafik yoğunluğu (11.74%), araç tipi (11.37%) ve bölge türü (8.07%) olup, toplamda model etkisinin yaklaşık %46'sını oluşturmuştur.
- Yorum: Kara Kutu skorunun devre dışı kaldığı durumda, risk sınıflandırması doğrudan çevresel ve coğrafi koşullara dayanmaktadır. Bu da özellikle düşük ve orta riskli kargo bölgelerinde hava, trafik ve araç planlamasına odaklanmanın riski düşürmede en etkili strateji olduğunu göstermektedir.

# ÇIKARIMLAR

Modelin Gücü: XGBoost sınıflandırma modeli, DF2\_disruption\_likelihood\_score ile eğitildiğinde  $F1 = 1.00$  elde etti. Ancak bu, skorun %97 etkisiyle oluşan yapay bir başarıydı. Skorsuz testte model  $F1 = 0.6393$  ile çalıştı, bu da gerçek performansı gösterdi.

Veri Sırrı: DF2 skoru, firmanın 'Kara Kutu' kurallarına göre çalışıyor ( $R^2 < 0$ ). Model bu skoru kullanarak %100 doğru sınıflandırma yapabiliyor, ancak nedenini açıklayamıyor.

- Projenin asıl değeri, risk yönetimini Kara Kutu'dan bağımsız olarak hava durumu ve trafik gibi eyleme dönük faktörlere dayandırmaktır.

# OPERASYONEL YATIRIM

Analiz sonuçları, kargo riskinin büyük ölçüde çevresel ve operasyonel faktörlerden kaynaklandığını göstermektedir. Bu nedenle, şirketlerin proaktif ve veri odaklı stratejiler geliştirmesi kritik önemdedir.

Öneri: Hava durumu, trafik yoğunluğu ve araç tipi değişkenlerine dayalı otomatik rota planlama, erteleme ve araç tipi optimizasyon sistemleri kurulmalıdır.

Beklenen Etki:

- Ani hava değişimleri veya yoğun trafik durumlarında hızlı tepki sağlanır.
- Teslimat güvenliği ve zamanında teslimat oranları artar.



# COĞRAFI RISK YÖNETİMİ

Bölge türü değişkeninin (%8.07) etkisi, bazı bölgelerde riskin daha yüksek olduğunu göstermektedir. Özellikle kırsal ve yarı kentsel bölgeler, ek önlemler gerektirmektedir.

## Öneri:

- Bu bölgelerde ek sigorta önlemleri ve güvenli taşıma protokolleri uygulanmalıdır.
- Yerel iş birlikleri ile riskli rotaların güvenliği artırılabilir.

## Beklenen Etki:

- Riskli rotalarda teslimat güvenliği sağlanır.
- Operasyonel ve finansal kayıplar azalır.

# TARTIŞMA

Bu çalışma, büyük veri ile makine öğrenimi uygulamalarında görülen kara kutu bağımlılığı ve metodolojik paradoksları ele almıştır.

Metodolojik Kanıt: Skorun mevcut özniteliklerle açıklanamayacağı kanıtlanmıştır. Bu, kurumun skor bağımlılığından kurtulmasını sağlayan kritik bir bulgudur.

Gerçek Performans ve Sınıf Yönetimi: Skor çıkarıldığında model, operasyonel veri ile ulaşılacak maksimum gerçek performansı yansıtmaktadır. Düşük ve orta risk sınıfları için gizli sinyaller mevcut değildir, model yalnızca yüksek riskleri güvenilir biçimde tanımaktadır.

Çıkarım: Model, risk sınıflandırmasında iş mantığına uygun ve güvenli bir davranış sergilemektedir. Bu, karar alma süreçlerinde güvenilir bir temel sağlar ve operasyonel önlemlerin hedeflenmesini kolaylaştırır.

# SONUÇ

Bu proje, tedarik zinciri risk modellemesinde en kritik çıktıyı sağlamıştır:  
Eyleme dönük bilgi (actionable contribution).

Kara kutusu devre dışı bırakıldığında, modelin gücünü oluşturan en önemli dört operasyonel faktör belirlenmiştir:

- Hava Koşulları
- Trafik Yoğunluğu
- Araç Tipi
- Bölge Türü

Bu faktörler, risk sınıflarında kayıpları azaltmak için şirketin doğrudan müdahale edebileceği alanları



# İLERİDEKİ ÇALIŞMA

## ALANLARI

### 1- Dış Veri Entegrasyonu:

- Modelin yakalama oranını artırmak için finansal volatilité verileri, tedarikçi performans kayıtları veya jeopolitik istikrar endeksleri gibi dış veri kaynakları eklenebilir.

### 2- Maliyet Odaklı Optimizasyon:

- Yalnızca genel F1 Skoru yerine, yüksek risk tahmin edilemediğinde maliyeti maksimize eden cost-sensitive learning yaklaşımı uygulanabilir.

### 3- Hassas Coğrafi Modelleme:

- Bölge türü faktörünün önemine dayanarak, lojistik risklerini daha hassas tahmin etmek için mahalle veya ilçe düzeyinde geospatial analizler yapılabilir.



# SCM SKORLAMA MANTIĞI

Risk genellikle Olasılık  $\times$  Etki formülü ile hesaplanır.

DF2\_disruption\_likelihoood\_score, bu formüldeki Olasılık bileşenini temsil eder.

Skor, basit bir ölçüm olmayıp dışsal faktörleri içerir:

- Finansal Sağlık / Kredi Puanı: Mevcut veri setinde yok.
- Jeopolitik Risk: Dış veri gerektirir.
- Kural Tabanlı Eşikler: Belirli kurallara dayalı, mevcut veri setinde yok.
- Tedarikçi Skoru: DF4\_RI\_Supplier1 ile temsil ediliyor; diğer bileşenler eksik.

Çıkarım: Skor, mevcut veri ile çözülemeyen Kara Kutu bir metriktir.

# KARA KUTU ÇÖZÜMLENMESİ SONRASI KİLOMETRE TAŞLARI

## Faz 02

Anlaşma sağlanacak bir firma ile  
çalışılarak modelin gerçek operasyonel  
veriler üzerinde doğrulanması

sağlanacaktır.

## Faz 01

Geliştirilen demo model kodlarının ve veri  
işleme süreçlerinin açık kaynak olarak  
paylaşılacağı bir Github deposu  
oluşturulacaktır.

## Faz 03

Elde edilen tüm bulgular, çözümlenen  
'Kara Kutu' içgörüler ve firma verileri  
kullanılarak bilimsel makale hazırlanıp  
literatüre katkı sunulacaktır.

# KAYNAKÇA

“VERİLER, DÖRT AÇIK KAYNAKLI E-TİCARET  
VE KARGO FIRMASINDAN ALINMIŞ OLUP,  
AKADEMIK ÇALIŞMA DEĞERİNİ KORUMAK  
AMACIYLA PAYLAŞILAMAMAKTADIR.”

## Kitaplar:

- Smith, J. A., & Brown, L. M. (2020). Supply chain risk management: Strategies and applications. Academic Press.
- Taylor, R. P. (2018). Data preprocessing in machine learning: Techniques and tools. Springer.

## Makale ve Konferans Bildirileri:

- Johnson, M. R., & Lee, S. H. (2019). Predicting disruptions in logistics: A machine learning approach. Journal of Transportation Research, 45(3), 123-135. <https://doi.org/10.1016/j.jitr.2019.01.005>
- Wang, Y., & Zhang, X. (2021). Enhancing supply chain resilience through data analytics. In Proceedings of the International Conference on Supply Chain Management (pp. 45-59). IEEE. <https://doi.org/10.1109/ICSCM.2021.00012>

## Raporlar ve Teknik Belgeler:

- European Commission. (2020). Impact of weather conditions on logistics operations. <https://ec.europa.eu/transport/sites/transport/files/weather-logistics-report.pdf>
- World Economic Forum. (2021). Global risks report 2021. <https://www.weforum.org/reports/the-global-risks-report-2021>

## Web Siteleri:

- Supply Chain Digital. (2022, March 15). How AI is transforming supply chain risk management. <https://www.supplychaindigital.com/technology/how-ai-transforming-supply-chain-ris>



# “İSTATİSTİKÇİSİZ İSTATİSTİK GÜVENİLİR DEĞİLDİR”

TÜRK İSTATİSTİK DERNEĞİ





Ege University

# TEŞEKKÜRLER

[mericozcan.com](http://mericozcan.com)

[linkedin.com/in/meriç-](https://linkedin.com/in/meriç-özcan)

[özcan](https://linkedin.com/in/meriç-özcan)

